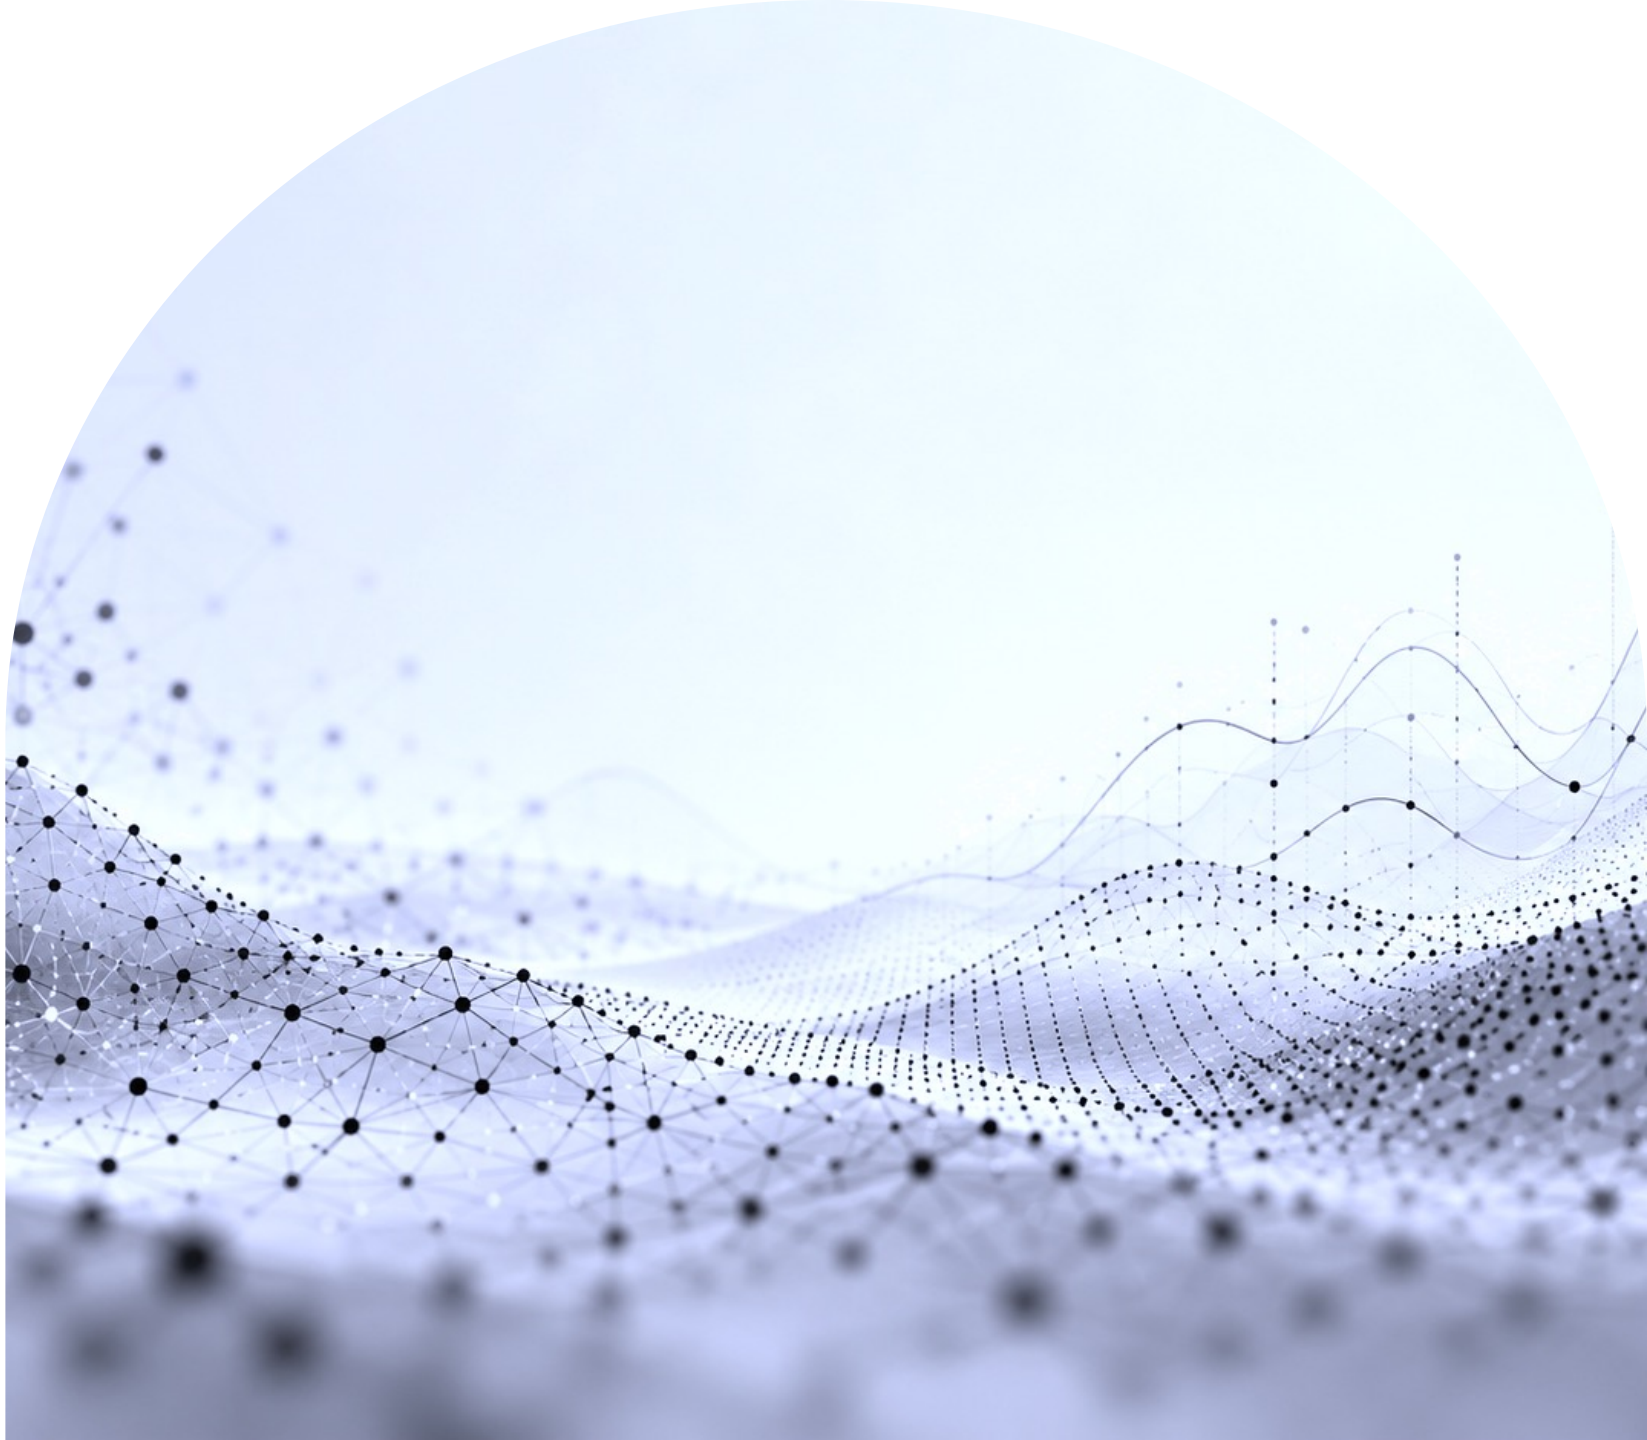
Maschinelles Lernen II



PoGS

Prof. Dr. Heinke Hihn

Agenda

1. Rückblick
2. Gemeinsame Projektarbeit am Beispiel
3. Projektarbeit im selbstgewählten Thema

Rückblick

1

Brauche ich überhaupt ML?

Klassisches ML

Für wiederkehrende Muster in Daten

Beispiele: Budgetprognose, Auslastung, molekulare Eigenschaften.

Vortrainierte Modelle

Für Texte, Fragen und dokumentengestützte Auswertung

Beispiele: Interviewcodierung, Literatursuche, Antragsprüfung.

Regeln & Optimierung

Für feste Randbedingungen und nachvollziehbare Entscheidungen

Beispiele: SHK-Zuteilung, Prüflisten, Ablaufplanung.

Typischer Ablauf eines ML Projekts

1

Problem

Was soll besser verstanden oder entschieden werden?

→

2

Daten

Welche Beobachtungen, Texte oder Regeln sind vorhanden?

→

3

Methode

Welcher einfachste Ansatz könnte funktionieren?

→

4

Prüfung

Woran erkennt ihr, ob das Ergebnis brauchbar ist?

Welche Modelle passen zu meinen Daten?

Ausgangslage	Mögliche Modellkandidaten
Tabulare Daten mit Zielvariable	Lineare / logistische Regression, Random Forest, Gradient Boosting
Viele Merkmale, wenige unabhängige Fälle	Regularisierte Regression, lineare SVM
Kleine bis mittlere Tabellen	Zusätzlich ein Tabular Foundation Model testen
Bilder oder Texte mit Labels	Vortrainierte Merkmale nutzen oder ein Modell durch Transfer Learning anpassen
Numerische Daten ohne Labels	K-Means, wenn Gruppen gesucht werden und das Distanzmaß sinnvoll ist

Wie viele Daten brauche ich?

Unter 100

Einfache, stark regularisierte oder vortrainierte Modelle prüfen

100–1.000

Klassische ML-Verfahren können bei überschaubaren Aufgaben gut funktionieren.

1.000–10.000

Mehr Spielraum für nichtlineare Modelle und systematische Vergleiche.

Über 10.000

Auch umfangreichere Modelle werden eher praktikabel.

Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. *NeuroImage, 180*, 68–77.

Wovon hängt der Datenbedarf ab?

- Schwierigkeit der Aufgabe
- Modellkomplexität
- Anzahl und Qualität der Merkmale
- Klassenverteilung
- Vorwissen und Vortraining
- Vielfalt der Anwendung
- Gewünschte Genauigkeit der Bewertung

Riley, R. D., Ensor, J., Snell, K. I. E., Harrell, F. E., Jr., Martin, G. P., Reitsma, J. B., Moons, K. G. M., Collins, G., & van Smeden, M. (2020). Calculating the sample size required for developing a clinical prediction model. *BMJ, 368*, Article m441. https://doi.org/10.1136/bmj.m441

Wenige Labels – welches Vorgehen passt?

Use Case: Ich habe nur wenige beschriftete Beispiele, möchtet aber Vorhersagen für neue Daten erhalten.

Vorgehen:

- **Zero-Shot Learning:** Ein passendes vortrainiertes Modell direkt auf die Aufgabe anwenden.
- **In-Context Learning:** Gelabelte Beispiele als Kontext bereitstellen, ohne die Modellgewichte zu verändern.
- **Transfer Learning:** Vortrainierte Merkmale nutzen oder das Modell mit eigenen Beispielen feinabstimmen.

- **Beispiel:** Für die Erkennung von Pflanzenkrankheiten stehen nur wenige annotierte Bilder zur Verfügung. Ein vortrainiertes Bildmodell liefert Merkmale, auf denen ein kleiner Klassifikator trainiert wird.

Auch ohne eigenes Gewichtetraining brauchen wir unabhängige Daten zur Überprüfung.

Modellauswahl – was soll später neu sein?

Die Datenaufteilung muss zur geplanten Anwendung passen.

Geplante Anwendung	Aufteilung für Training und Test
Neue unabhängige Fälle aus derselben Population	Zufällige Aufteilung
Neue Personen oder Proben	Personen bzw. Proben vollständig trennen
Zukünftige Beobachtungen	Frühere Daten zum Training, spätere zum Testen
Neue Labore oder Standorte	Ganze Labore bzw. Standorte zurückhalten

Beispiel: Mehrere Bildausschnitte derselben Probe dürfen nicht auf Training und Test verteilt werden, wenn das Modell später neue Proben erkennen soll.

Gemeinsame Projektarbeit

Klassifikation von Texten

2

Eure Themen in Kategorien

Texte & Wissen

Offene Befragungen · Interviews · Policy-Dokumente · Anträge · Literatur und Code

Daten & Prognosen

Budgets · Cloud-Auslastung · Moleküleigenschaften · Genotyp-Umwelt-Effekte

Assistenz & Planung

SHK-Einsatz · Trainingsdialoge · Lehre · Grundrechte-Prüfung

Methoden für eure Projekte

- **Textanalyse, NLP und LLMs 9/13**
  - Textklassifikation, Embeddings, semantische Suche, Informationsextraktion

- **Vorhersagen aus strukturierten Daten 4/13**
  - Regression, Random Forest, Gradient Boosting, Zeitreihen

- **Optimierung und regelbasierte Systeme 1/13**
  - Constraint Optimization, Zuordnung, Entscheidungsregeln

Sessions heute

Session 1	Session 2
Informationen strukturieren	Ergebnisse vorhersagen
Häufig kein gelabelter Datensatz vorhanden	Häufig Zielvariable vorhanden
Embeddings und Sprachmodelle	Entscheidungsbäume und Ensemble-Modelle
Unsupervised und Zero-Shot Learning	Supervised Learning und Anomalieerkennung
Bewertung durch menschliche Codierung, Themenkohärenz und Retrieval-Relevanz	Bewertung mit Vorhersagefehlern, CV und Baselines
Qualitative und dokumentenbasierte Forschung	Quantitative und experimentelle Forschung

Zusammenhang Projekte und Sessions

Projekt	Session 1: Text	Session 2: Prediction
Genetik / Code-Library	●	●
Führung / qualitative Ratings	●	◐
Cloud-Ressourcen	–	●
Fördermittelanträge	●	–
SHK-Aufgabenplanung	◐	–
Evidenzmatrix / historische Quellen	●	◐
Landschaftsrestaurierung	●	◐
Therapeutische Trainingssimulation	◐	–
Photosäuren	–	●
Budgetplanung	–	●
Medienwissenschaftliche Lehre	●	–
KI und Recht	●	–

● Direkte Anwendung · ◐ Methodisch teilweise relevant · – Nicht zentral

Plan für Heute

1 Passenden Ansatz wählen

ML, vortrainiertes Sprachmodell, Optimierung oder klassische Methode?

2 Praktisch ausprobieren

Ein kleines Experiment durchführen und seine Ergebnisse kritisch prüfen.

3 Konkret weiterarbeiten

Für das eigene Projekt den nächsten machbaren Schritt festlegen.

Projektarbeit

3

Zentrale Fragen eines ML Projekts

1. Was soll am Ende vorliegen: Zahl, Kategorie, Suche, Empfehlung oder Entscheidung?
2. Welche Beispiele, Daten oder Dokumente existieren heute schon?
3. Welche Aufgabe löst ihr bislang manuell – und was wäre eine einfache Baseline?
4. Wie würdet ihr zehn Ergebnisse fachlich überprüfen?

Output: eine klare Aufgabe + Datenquelle + Erfolgskriterium.

Was ist ein gutes Ergebnis?

Menschliche Übereinstimmung

Sind unsere Kategorien selbst eindeutig?

Modellfehler

Welche Aussagen werden falsch oder gar nicht erkannt?

Wissenschaftliche Validität

Messen wir tatsächlich das gewünschte Konstrukt?

Labor A: Texte automatisch erschließen

1 · Daten erkunden und bereinigen

2 · Einfaches Basismodell: Wörter/Begriffe zählen

3 · Texte gruppieren

4 · Themen und Stimmung analysieren

5 · Eigene Kategorien anwenden

https://huggingface.co/spaces/heinkehihn/TextSession

Datenquelle: https://huggingface.co/datasets/Hannes111/student_feedback_sentiment

Labor B: Klassifikation

1 · Daten Erkunden: Zielvariable und verfügbare Eingaben festlegen

2 · Daten Vorbereiten: Fehlende Werte, Duplikate, Normalisierung

3 · Einfache Modelle als Baselines trainieren

4 · Komplexe Modelle und Optimierung

5 · Performance analysieren

https://heinkehihn-classsession.hf.space/

Allgemeine Tipps

Wie gehe ich vor?

7

Vom Datensatz zum ersten Modell

1. **Eine konkrete Teilfrage auswählen:** Zunächst eine klar definierte Zielvariable und einen überschaubaren Datensatz bearbeiten.

2. **Einzelne Fälle ansehen:** Einige Rohdaten und Labels manuell prüfen. Stimmen Einheiten, Zuordnungen und Kategorien?

3. **Eine einfache Baseline erstellen:** Erst prüfen, was mit Mehrheitsklasse, Mittelwert oder einem einfachen Modell erreichbar ist.

4. **Den gesamten Ablauf einmal durchlaufen:** Daten einlesen, aufteilen, Modell trainieren und Vorhersagen prüfen – bevor umfangreich optimiert wird.

5. **Experimente nachvollziehbar halten:** Datenversion, verwendete Merkmale, Modellkonfiguration und Ergebnisse dokumentieren.

Die Daten Selbst verstehen

- **Den Vorhersagezeitpunkt festlegen:** Welche Informationen wären in der späteren Anwendung tatsächlich schon verfügbar?
- **IDs und technische Merkmale prüfen:** Dateinamen, Gerätekennungen oder Chargennummern können unerwünschte Abkürzungen ermöglichen.
- **Labels hinterfragen:** Uneinheitliche Annotationen oder unklare Kategorien begrenzen die Aussagekraft der Evaluation.
- **Fehlende Werte verstehen:** Wurde etwas zufällig nicht gemessen oder hängt das Fehlen mit der Zielvariable zusammen?
- **Augmentation richtig einordnen:** Veränderte Bilder oder zusätzliche Signalfenster können beim Training helfen, ersetzen aber keine unabhängigen Personen oder Proben.

Ergebnisse mit mehr als einem Score prüfen

- **Fehlvorhersagen untersuchen:** Welche Fälle werden verwechselt? Gibt es gemeinsame Eigenschaften?
- **Teilgruppen getrennt betrachten:** Funktioniert das Modell auch bei anderen Standorten, Geräten oder relevanten Personengruppen?
- **Den Mehrwert einzelner Datenquellen testen:** Wird das Modell ohne eine Merkmalsgruppe tatsächlich schlechter?
- **Eine Änderung nach der anderen testen:** So bleibt erkennbar, wodurch eine Verbesserung entstanden ist.
- **Ein Abbruchkriterium festlegen:** Wann ist die Leistung fachlich ausreichend? Wann lohnt sich weiteres Tuning nicht mehr?

Systematisch Experimentieren

Führe ein Protokoll über die Experimente

Experiment	Was wurde verändert?	Validierungsergebnis	Fachlich relevante Fehler	Nächster Schritt
Baseline	Mehrheitsklasse	...	Seltene Klasse wird nie erkannt	Einfaches Modell testen
Modell 1	Logistische Regression	...	...	Merkmale prüfen
Modell 2	Gradient Boosting	...	...	Mehrwert gegenüber Modell 1 beurteilen