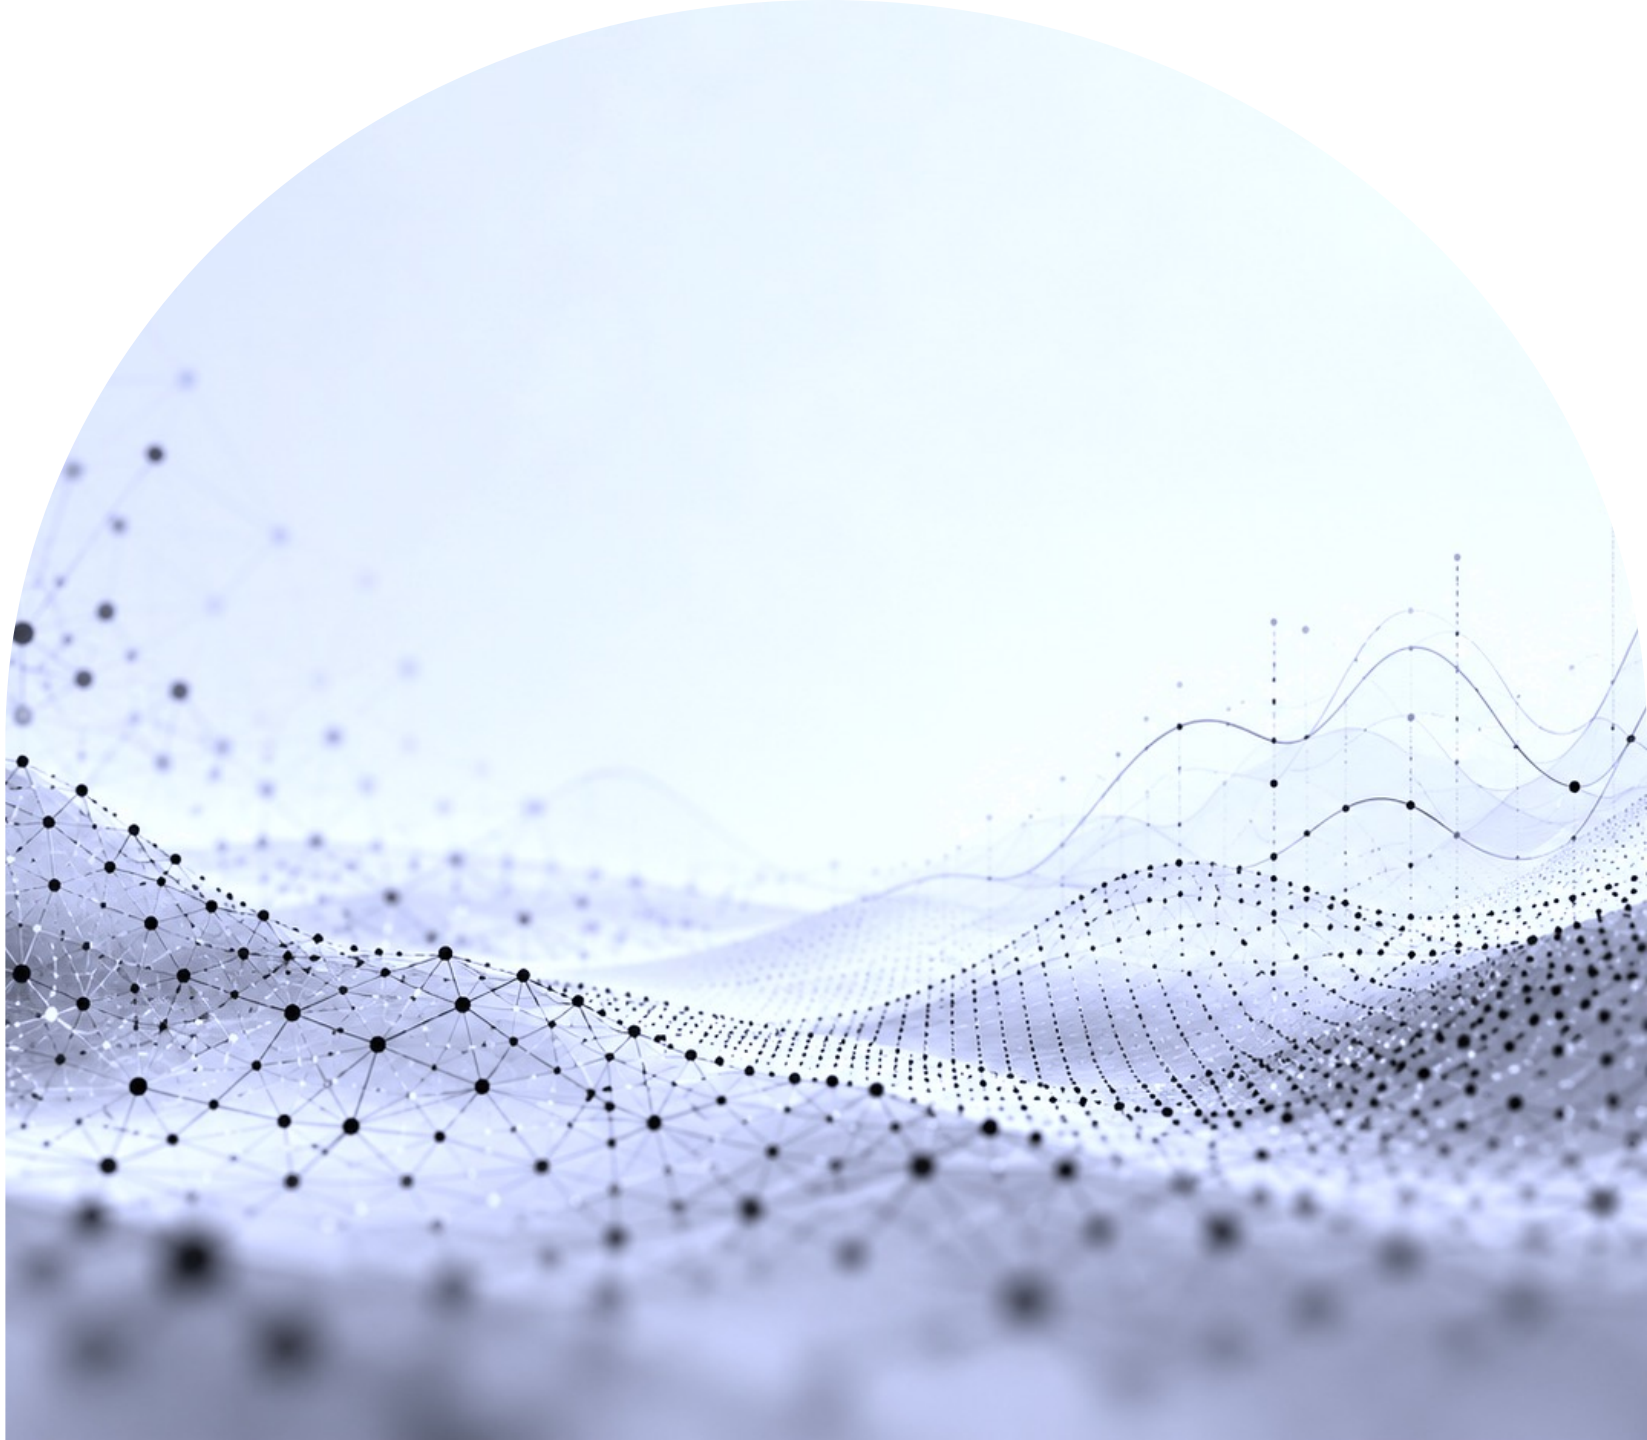
Maschinelles Lernen



POGS

Prof. Dr. Heinke Hihn

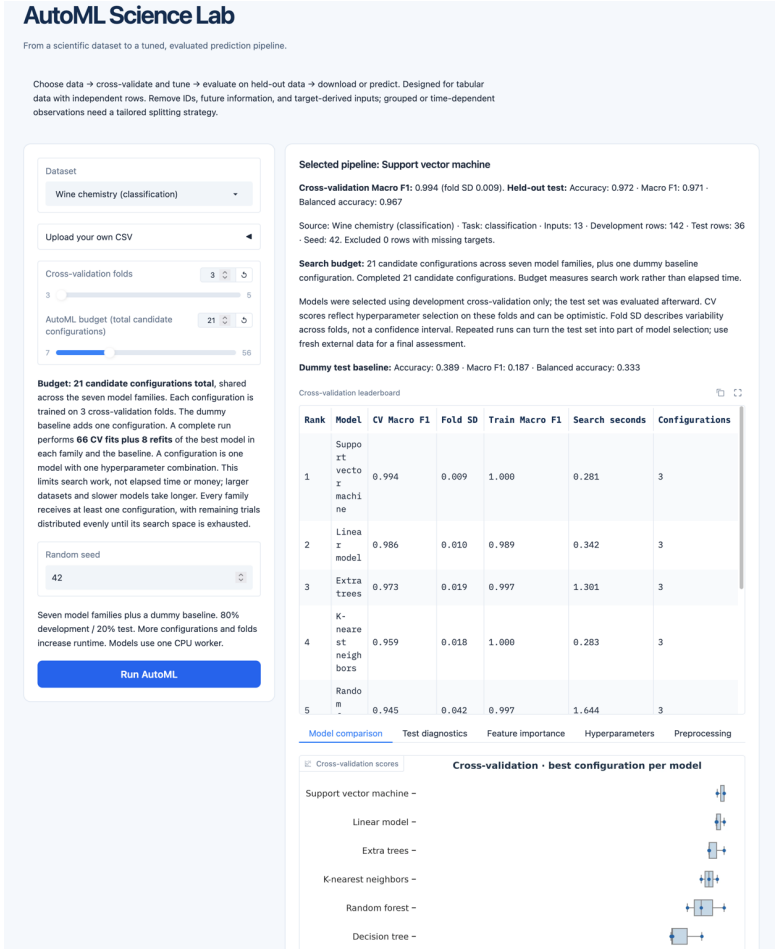
Ausblick

Ziel des Workshops: Selbstständig Machine Learning Use Cases erkennen, planen und anwenden.

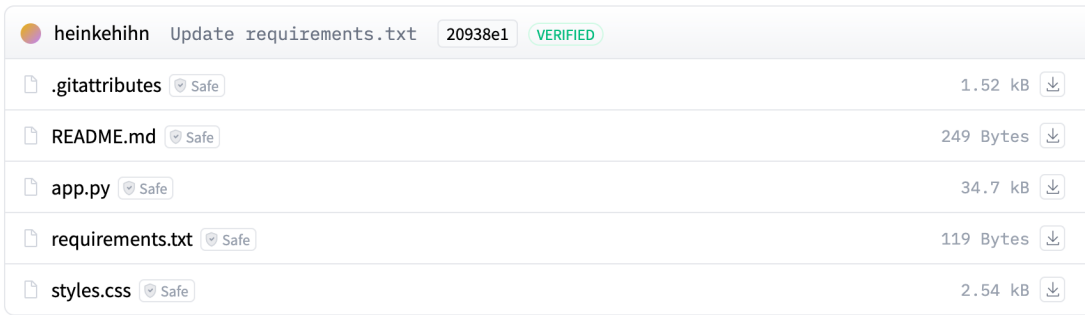
1. Was ist Machine Learning?
2. Machine Learning Modelle
3. Pain Points in Machine Learning durch AutoML vereinfachen
4. Lernen mit keinen (oder wenigen) eigenen Daten durch Zero Shot Learning
5. Modelle zur systematischen Entwicklung von Machine Learning based Science workflows
6. Hands-On Projektarbeit

Alle Materialien unter https://github.com/hhihn/MachineLearning4Science

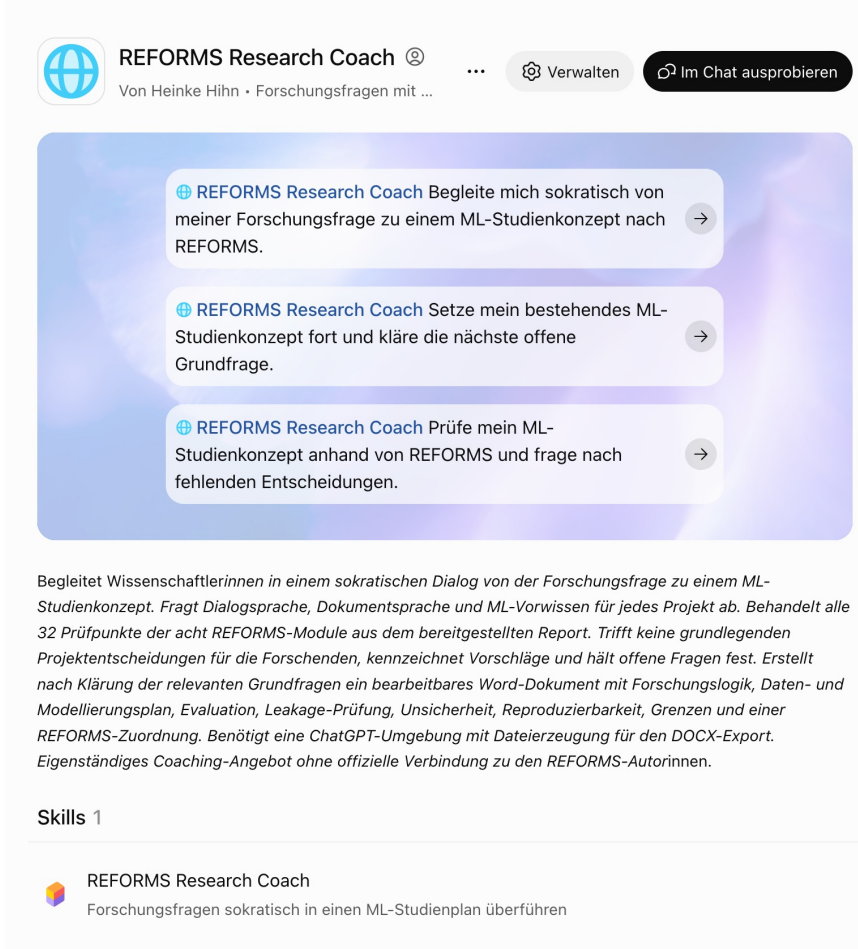
Übungen

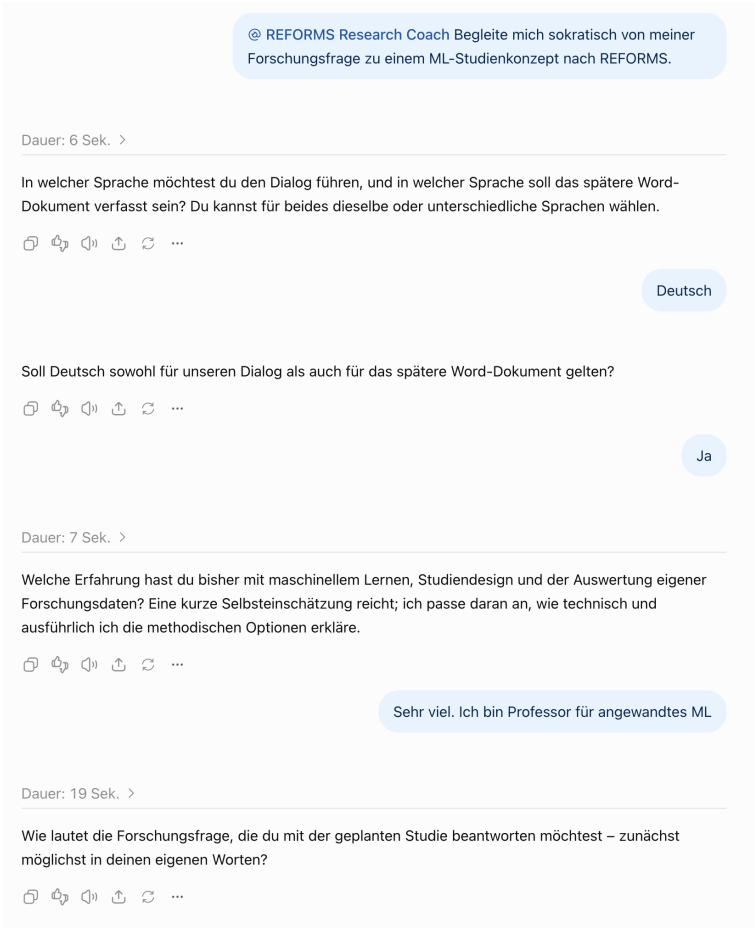


Web-Interfaces als Huggingface Spaces und Code öffentlich verfügbar



REFORMS Research Coach





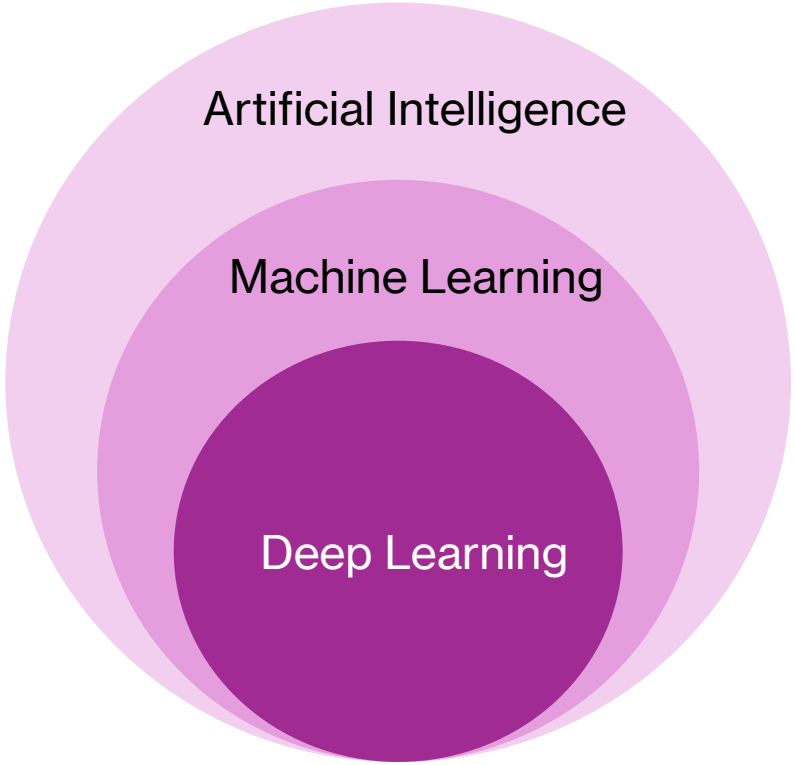
Definition und Einführung

Machine Learning Basics

1

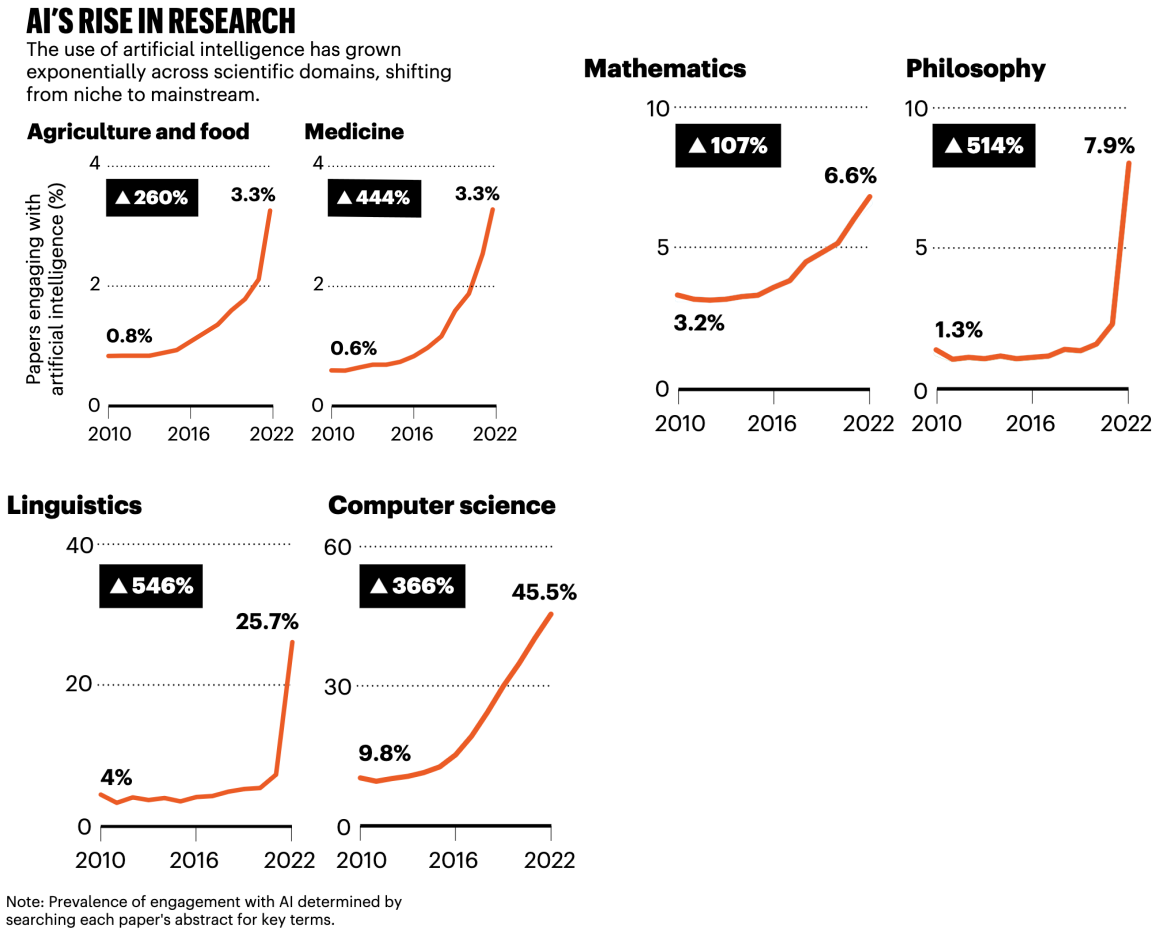
Definition

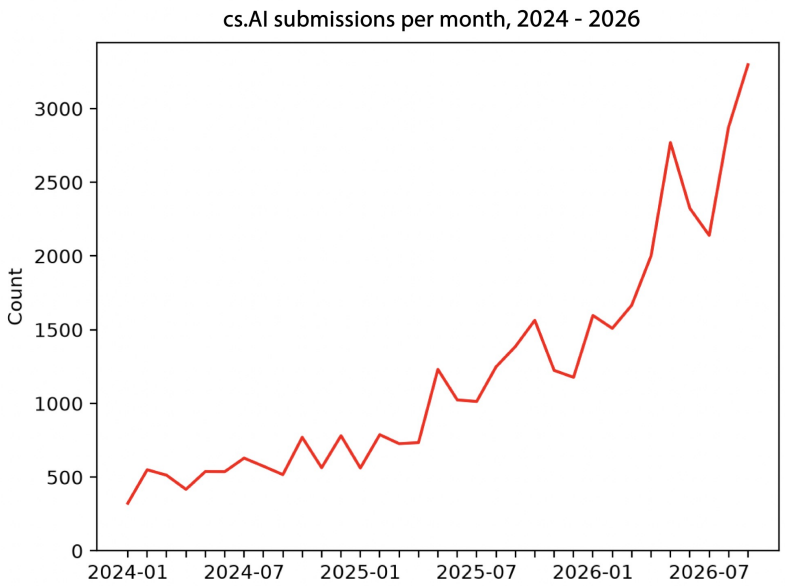
“Machine Learning ist ein Teilbereich der künstlichen Intelligenz (KI), bei dem Computer aus **Daten lernen** und sich mit der Erfahrung verbessern, **ohne explizit programmiert** zu werden.“



https://www.sap.com/germany/resources/what-is-machine-learning

ML & AI Paper bei arXiv





Narayanan, A., & Kapoor, S. (2025). Why an overreliance on AI-driven modelling is bad for science. *Nature*, *640*(8058), 312-314, https://blog.arxiv.org/2026/10/01/updated-rate-limit-policy/

Komponenten

Daten

Metriken

Modell

Sichtweise auf Lernprobleme

Klassisch ist die anwendungsoriente Sichtweise:

Supervised vs. Non-Supervised vs. Reinforcement Learning

Alternative datenorientierte Sichtweise:

Strukturierte vs. Nicht-strukturierte Daten

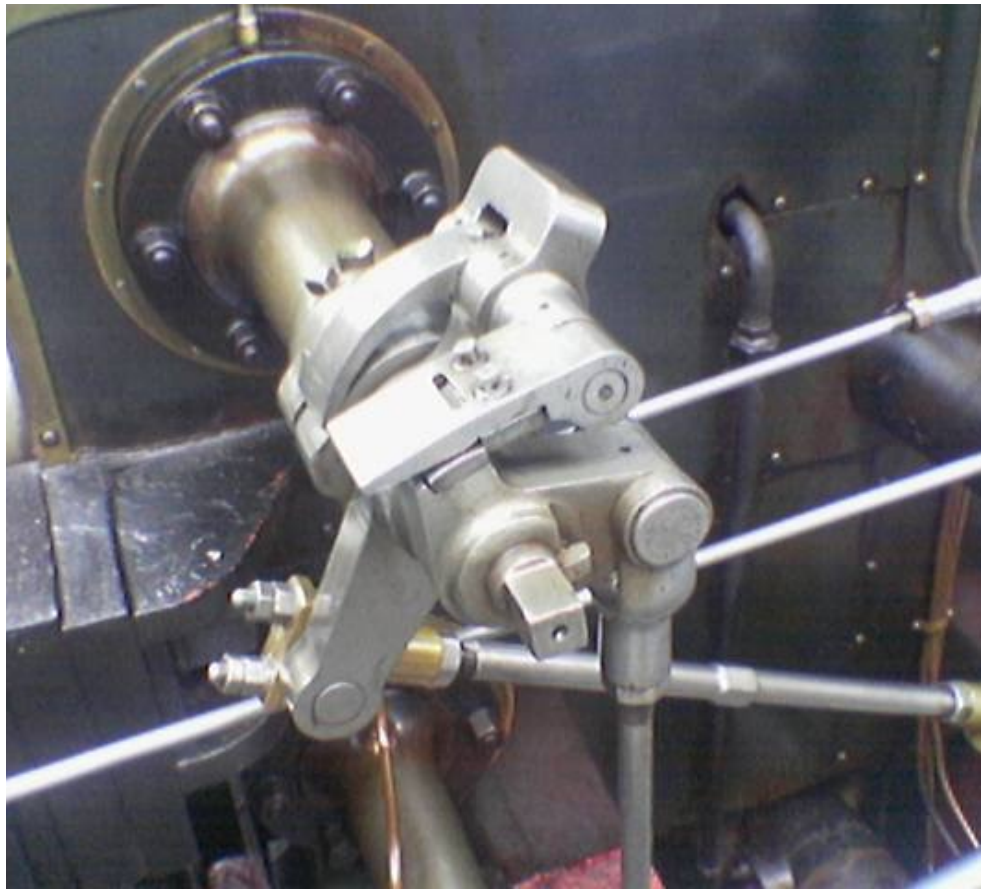
Strukturierte und Unstrukturierte Daten

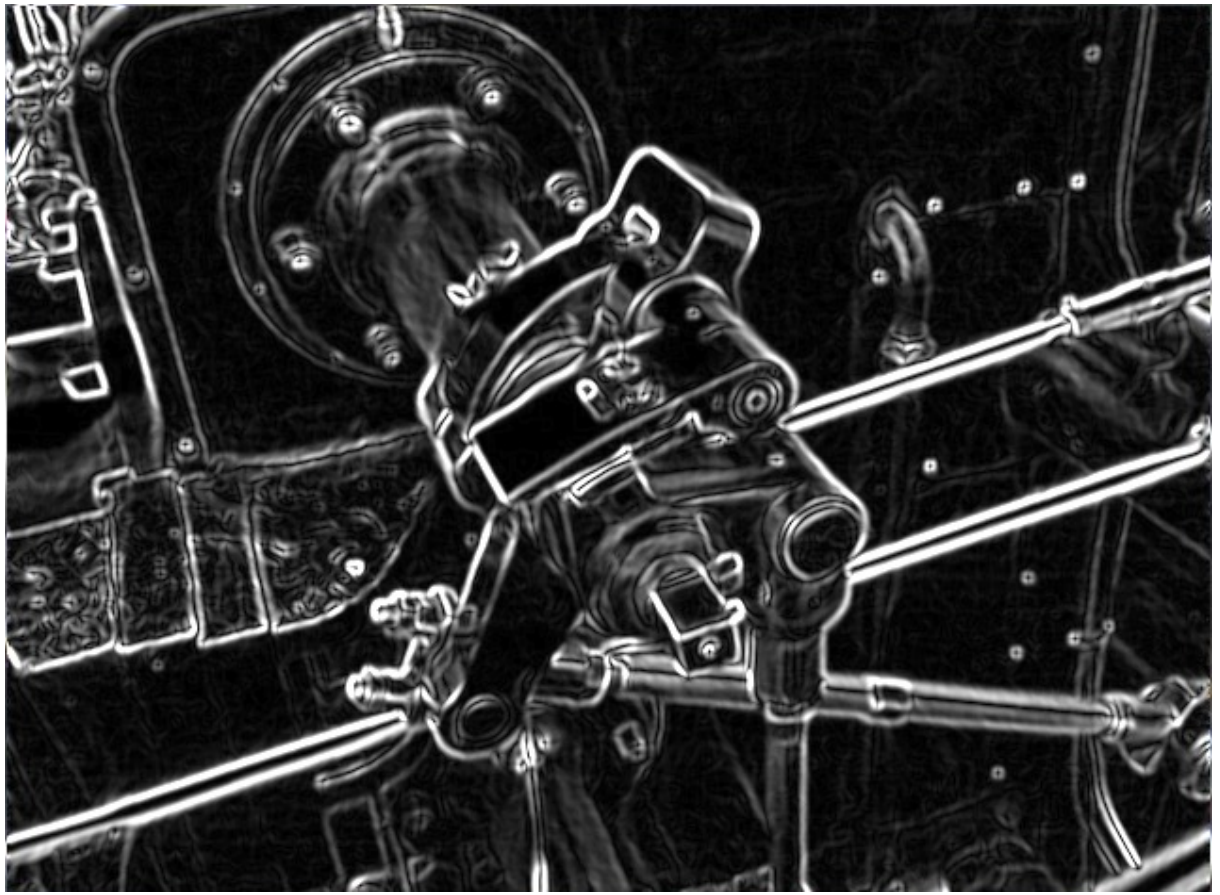
Strukturierte Daten	Unstrukturierte Daten
Matrizen mit Zeilen (Sample) und Spalten (Feature)	Kein vordefiniertes Format
Stark heterogen	Stark homogen
Keine natürliche räumliche oder zeitliche Struktur	Lokale oder sequentielle Kohorenz
Keine direkt Tokenisierung	Tokenisierung möglich
Tabellen	Texte, Bilder, Audiodaten, ...

Tabulare Daten

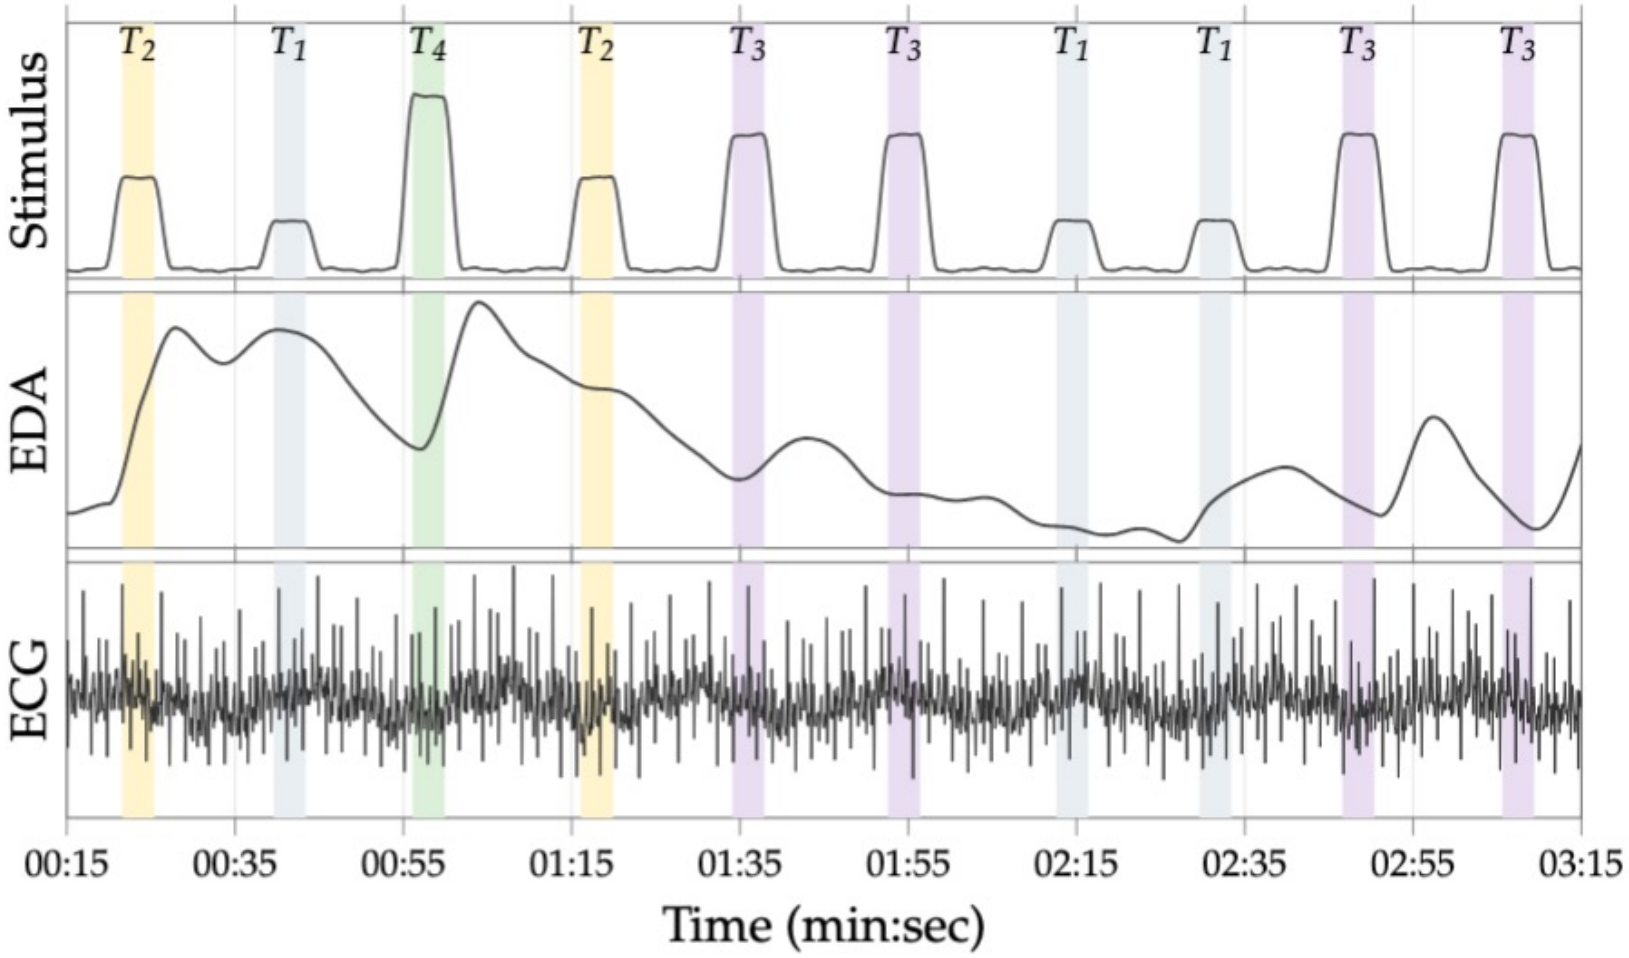
GENDER string · classes	AGE int64	SMOKING int64	YELLOW_FINGERS int64	ANXIETY int64	PEER_PRESSURE int64	CHRONIC DISEASE int64	FATIGUE int64	ALLERGY int64	WHEEZING int64	ALCOHOL CONSUMING int64	COUGHING int64	SHORTNESS OF BREATH int64	SWALLOWING DIFFICULTY int64	CHEST PAIN int64	LUNG_CANCER string · classes
2 values	21 87	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	1 2	2 values
M	69	1	2	2	1	1	2	1	2	2	2	2	2	2	YES
M	74	2	1	1	1	2	2	2	1	1	1	2	2	2	YES
F	59	1	1	1	2	1	2	1	2	1	2	2	1	2	NO
M	63	2	2	2	1	1	1	1	1	2	1	1	2	2	NO
F	63	1	2	1	1	1	1	1	2	1	2	2	1	1	NO
F	75	1	2	1	1	2	2	2	2	1	2	2	1	1	YES
M	52	2	1	1	1	1	2	1	2	2	2	2	1	2	YES
F	51	2	2	2	2	1	2	2	1	1	1	2	2	1	YES
F	68	2	1	2	1	1	2	1	1	1	1	1	1	1	NO
M	53	2	2	2	2	2	1	2	1	2	1	1	2	2	YES
F	61	2	2	2	2	2	2	1	2	1	2	2	2	1	YES
M	72	1	1	1	1	2	2	2	2	2	2	2	1	2	YES
F	60	2	1	1	1	1	2	1	1	1	1	2	1	1	NO
M	58	2	1	1	1	1	2	2	2	2	2	2	1	2	YES
M	69	2	1	1	1	1	1	2	2	2	2	1	1	2	NO
F	48	1	2	2	2	2	2	2	2	1	2	2	2	1	YES

Bildverarbeitung

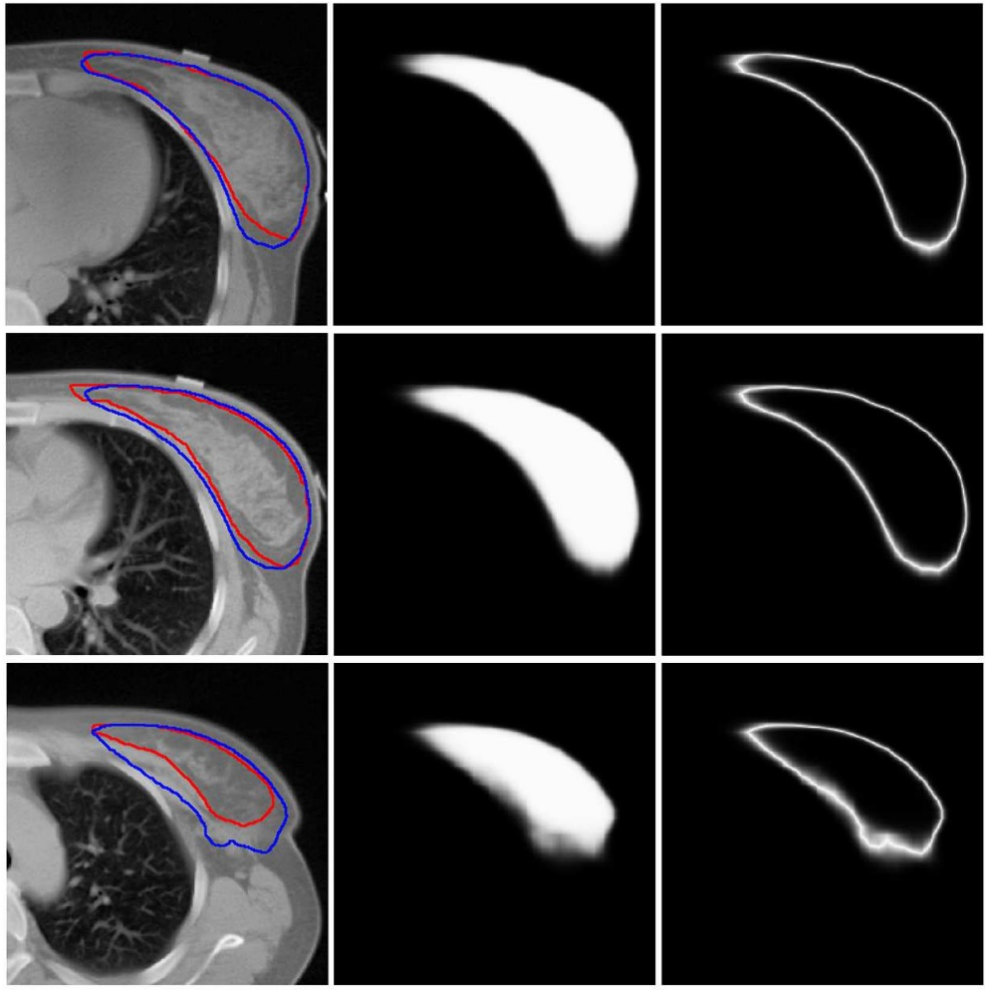




Zeitreihenklassifikation



Segmentierung



Typische Fehlerquellen

- **Data Leakage (Datenleckage):** Unbeabsichtigtes Einfließen von Testset- oder Zukunfts-Informationen in das Training; erzeugt verfälschte Performanzwerte.
  - *Preprocessing Leakage:* Normalisierung, Imputation oder Feature-Selektion vor dem Datensplit.
  - *Label & Duplicate Leakage:* Verwendung von Nach-Ereignis-Proxies oder identischen Einheiten in Train und Test.

- **Shortcut Learning:** Erlernen oberflächlicher Korrelationen (z. B. Gerätemarker auf Röntgenbildern) statt kausaler Muster; führt zum Leistungskollaps unter *Out-of-Distribution* (OOD)-Bedingungen.

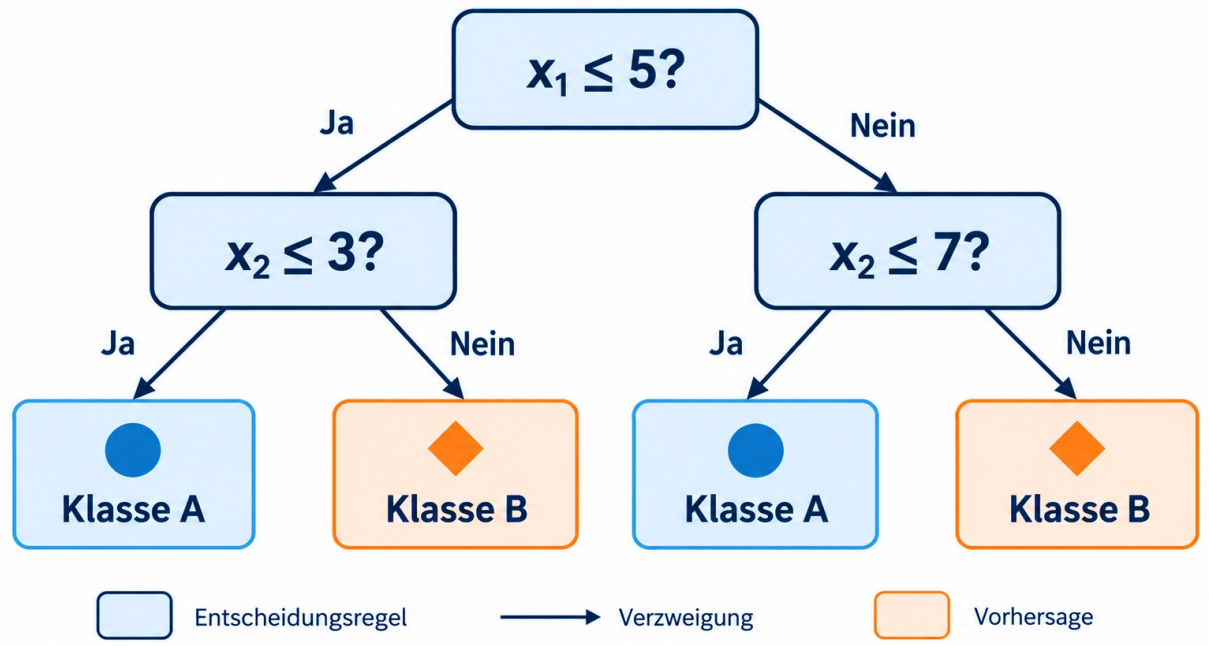
- **Qualitätssicherung:** Verbindliches Auditing von Modellentscheidungen anhand standardisierter Checklisten (*REFORMS*, *Model Info Sheets*, *TRIPOD+AI*).

Entscheidungsbäume

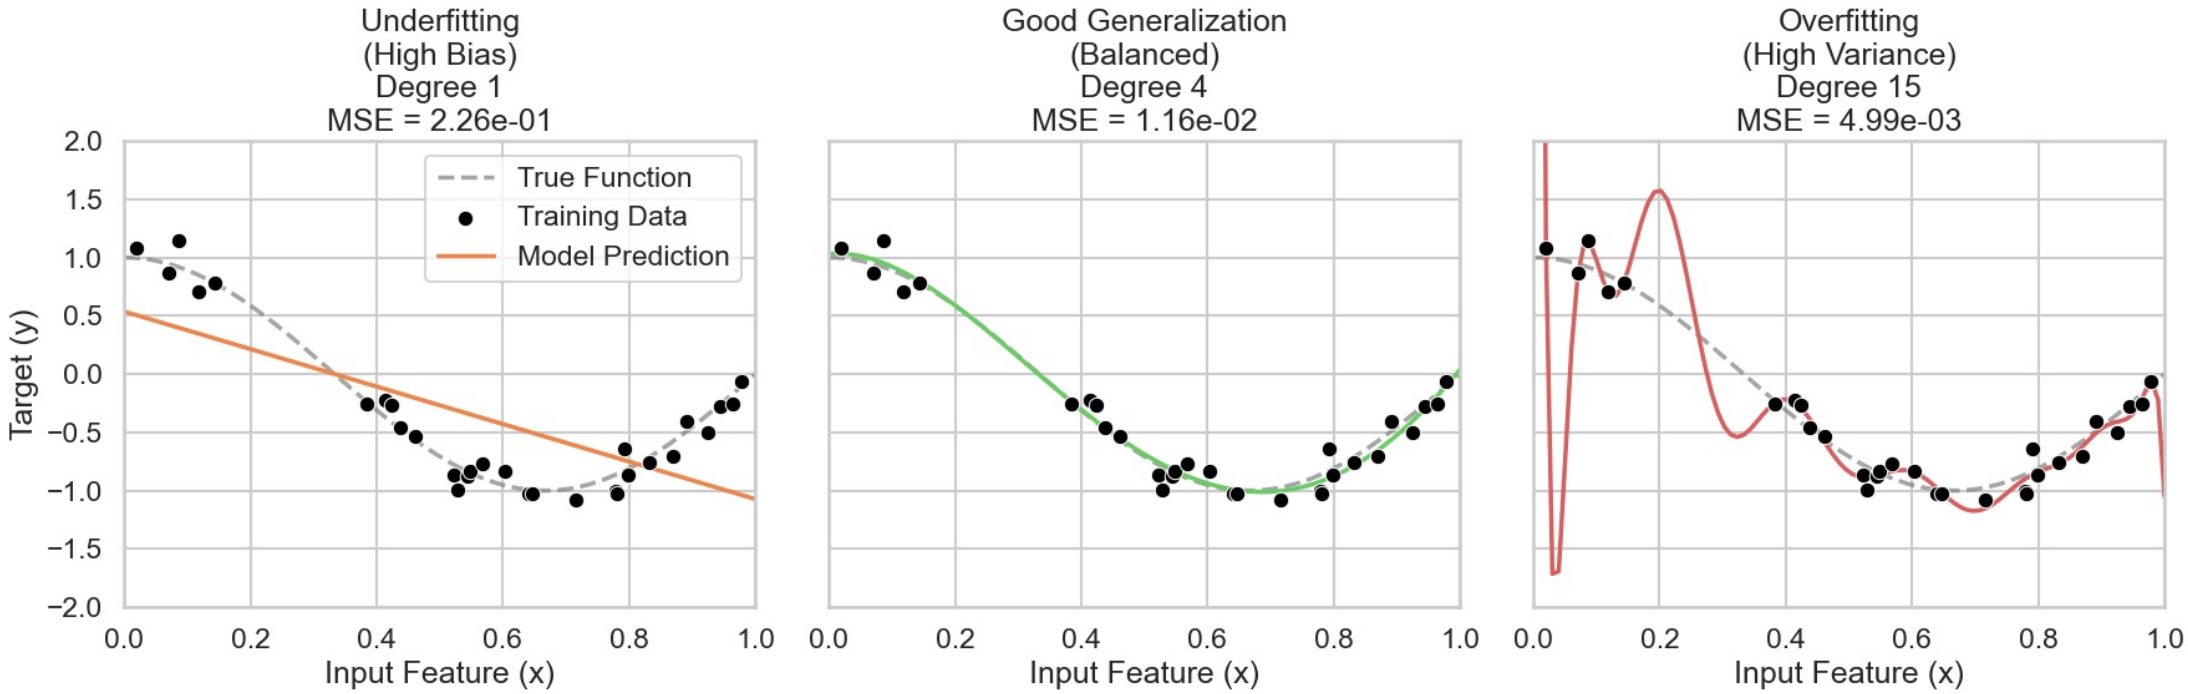
Überwachtes Lernverfahren für

- Classification & Regression
- Kontinuierliche und kategorische Daten
- Lineare- und nicht-lineare Probleme

Sehr gut interpretierbar



Überanpassung von Modellen – Overfitting & Underfitting



Machine Learning Einführung - Übung

https://huggingface.co/spaces/heinkehihn/BasicLearning

1. Welche Vorhersageaufgaben bearbeitet die App mit dem Wine- und dem Diabetes-Datensatz, und worin unterscheiden sich Klassifikation und Regression?

2. Warum teilt die App die Daten in Trainings-, Validierungs- und Testdaten auf und hält die Testdaten während der Experimente verborgen?

3. Wie würdet ihr für den Wine-Datensatz einen Entscheidungsbaum mit maximaler Tiefe 3 trainieren und anhand der Konfusionsmatrix feststellen, welche Klassen verwechselt werden?

4. Wie verändern sich Trainings- und Validierungsleistung im Modellvergleich, wenn ihr bei gleichem Zufallsseed die maximale Baumtiefe erhöht, und welche Ergebnisse deuten auf Overfitting hin?

5. Welches Modell würdet ihr für euren Datensatz auswählen, wenn ihr Validierungsleistung, Abstand zur Dummy-Baseline, Trainingszeit und Stabilität über verschiedene Zufallsseeds berücksichtigt?

Machine Learning Modelle

Die gängisten Modelle

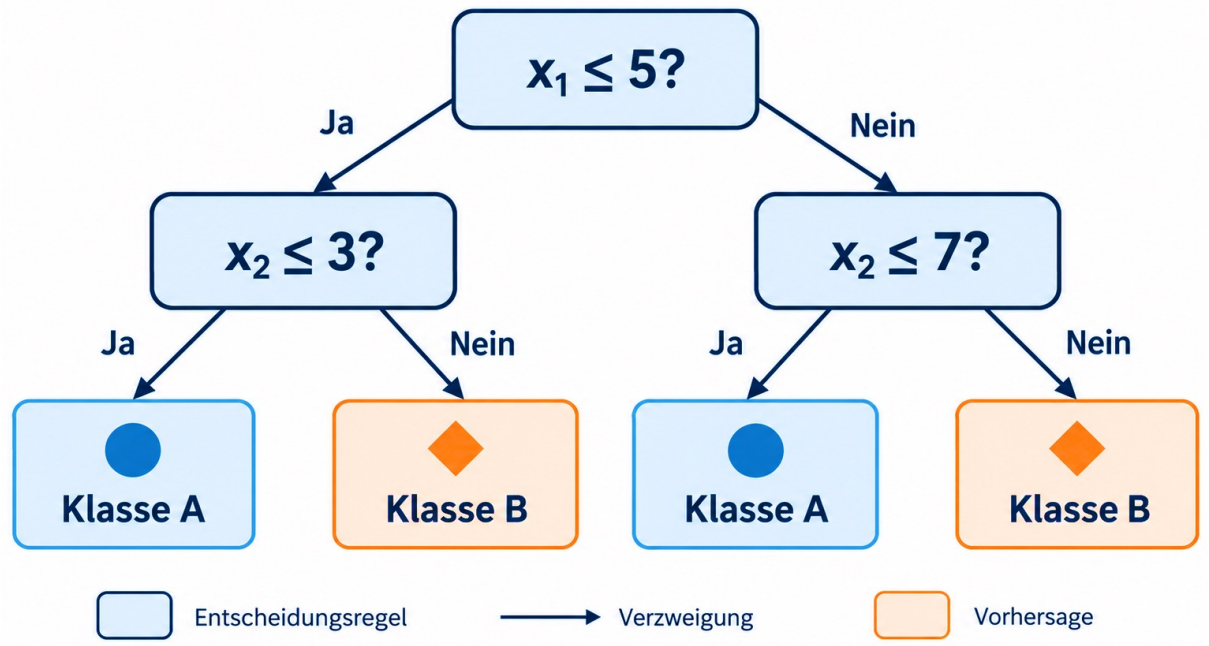
2

Entscheidungsbäume

Überwachtes Lernverfahren für

- Classification & Regression
- Kontinuierliche und kategorische Daten
- Lineare- und nicht-lineare Probleme

Sehr gut interpretierbar

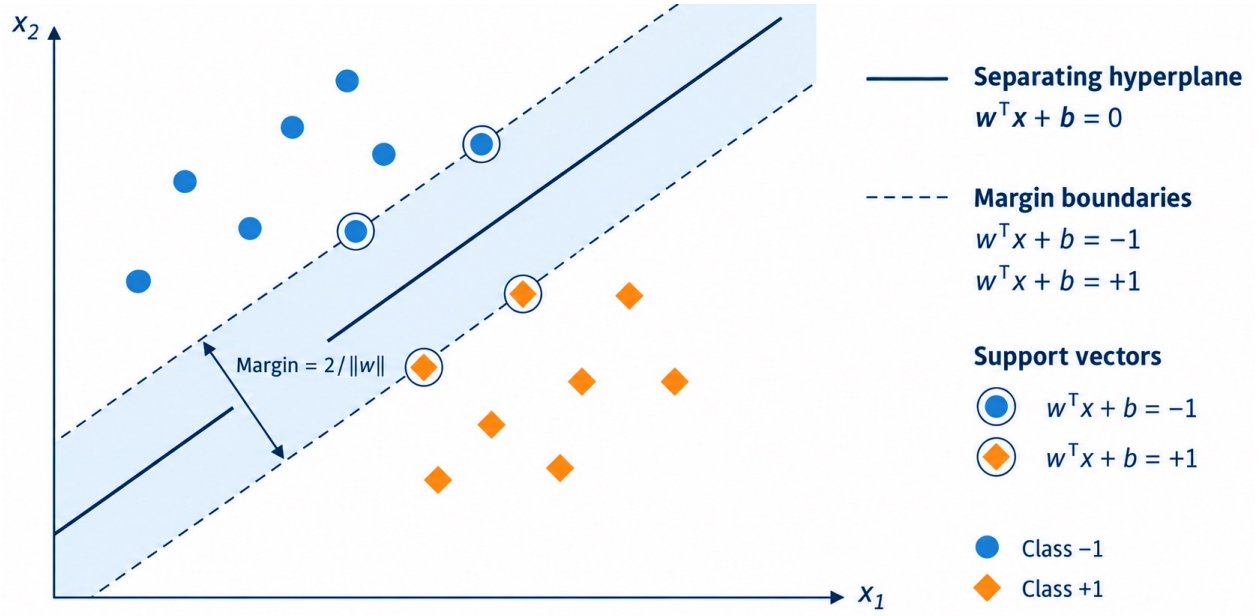


Support Vector Machines

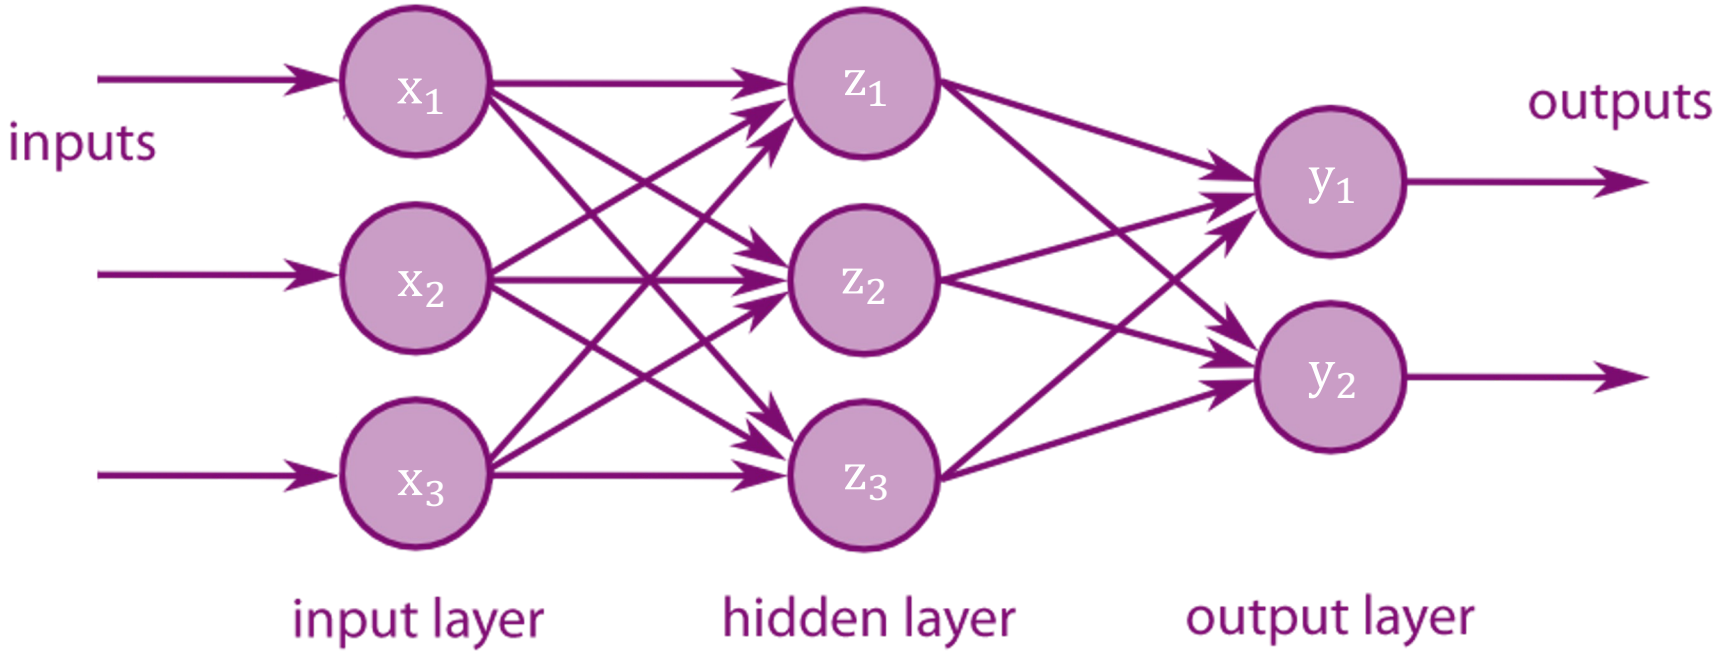
Überwachtes Lernverfahren für

- Classification & Regression
- Kontinuierliche und kategorische Daten
- Lineare- und nicht-lineare Probleme

Kann nur Binäre Entscheidungsprobleme lösen. Mehr Klassen kommen Kaskadierungen zum Einsatz



Neuronale Netze – Aufbau und Funktionsweise



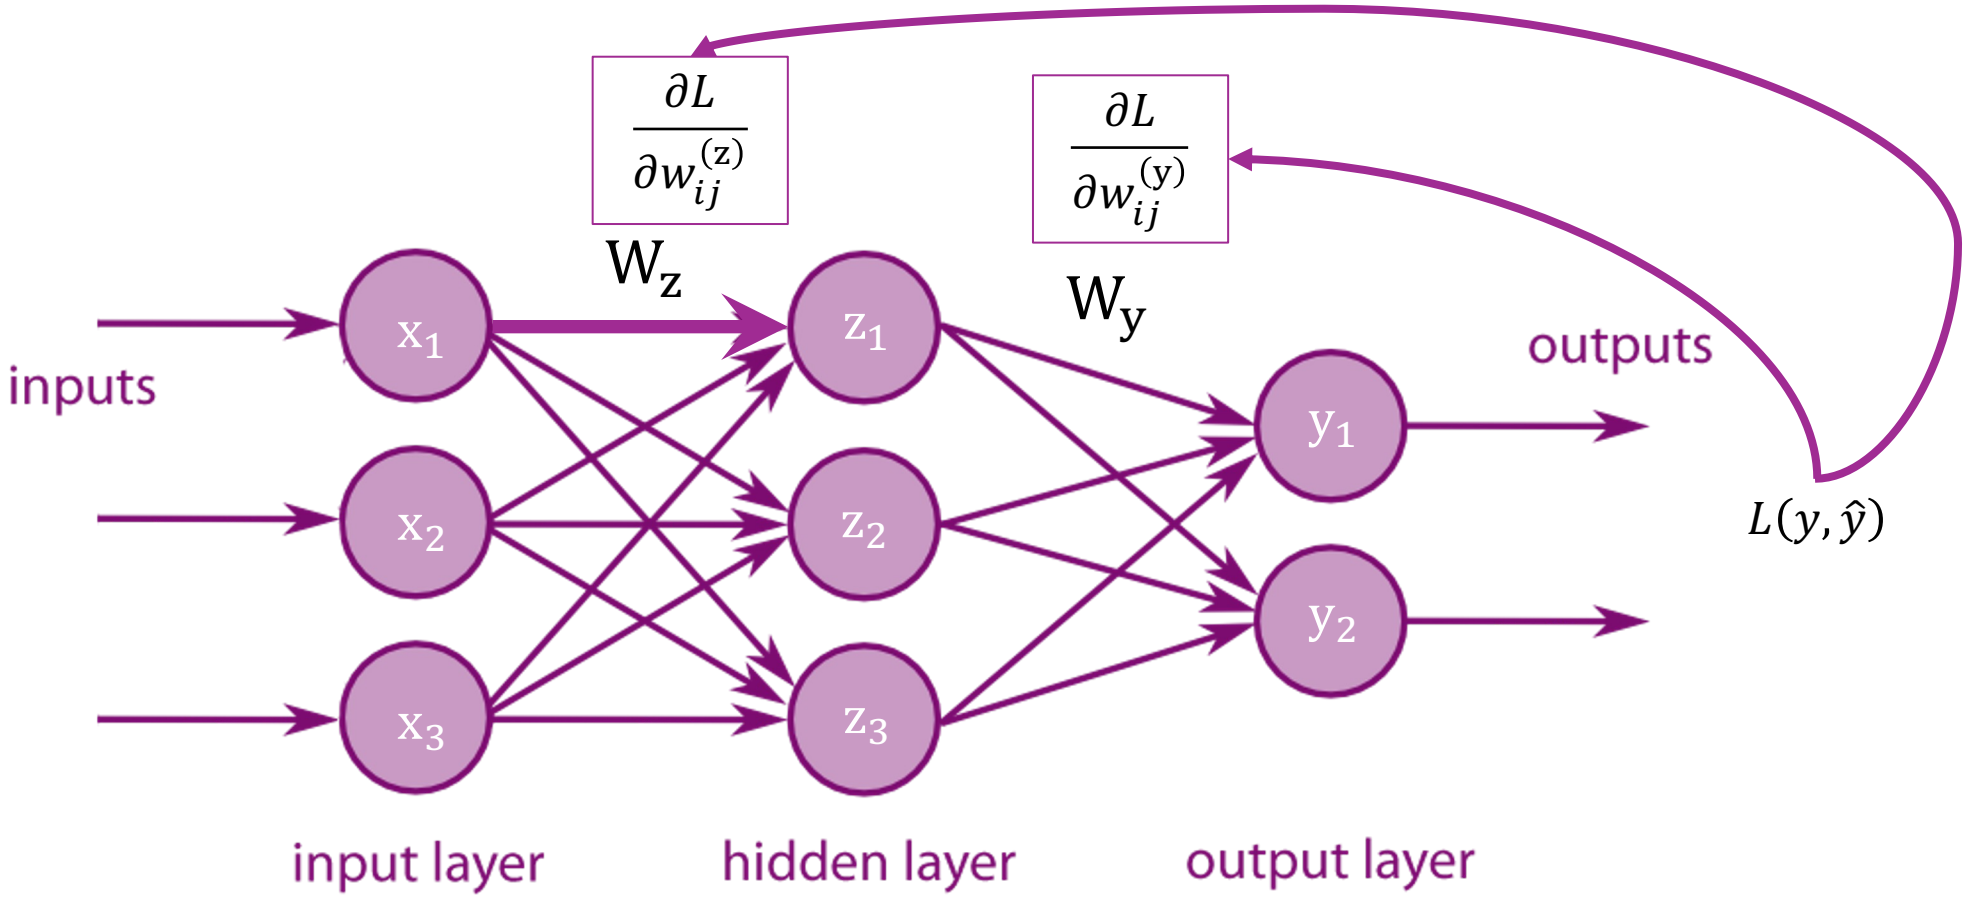
$$W_y = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \end{bmatrix}$$

$$W_z = \begin{bmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{bmatrix}$$

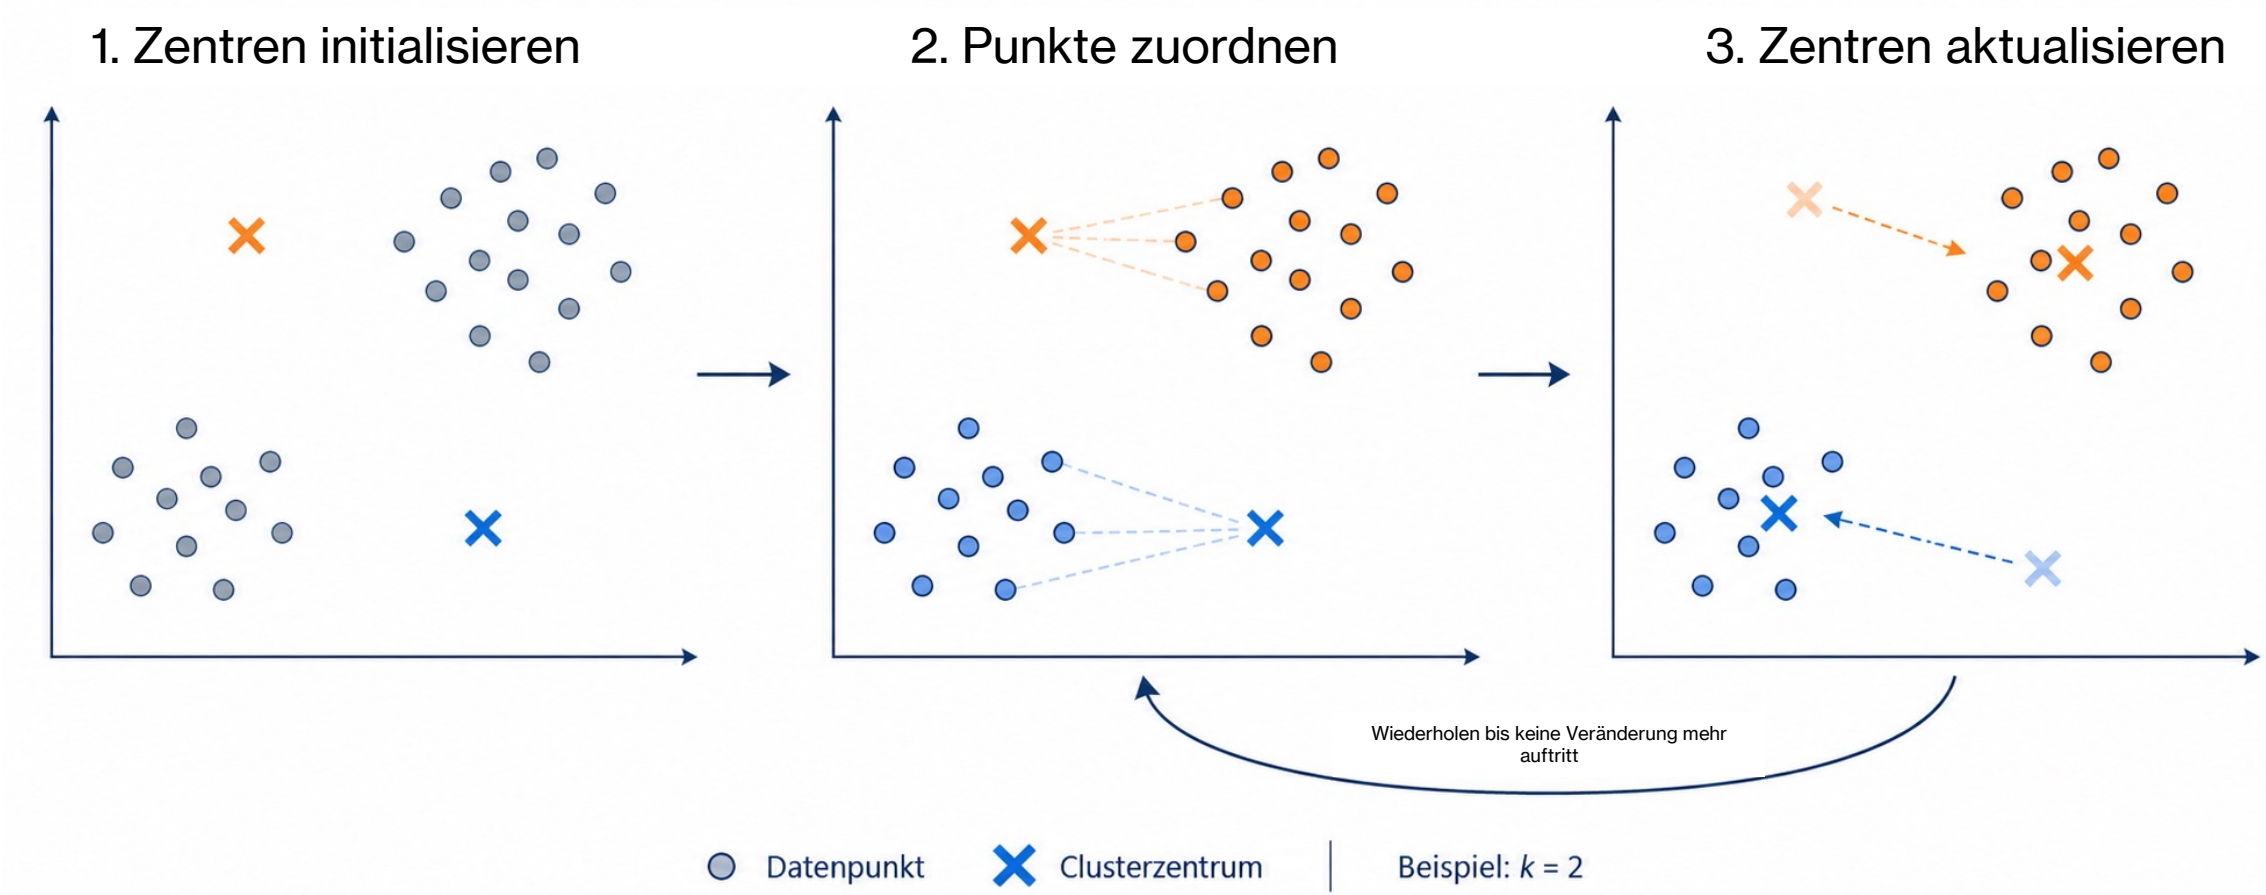
$$z_j = f\left(\sum_{i=1}^{N_{in}} w_{ji} x_i\right) \qquad y_j = f\left(\sum_{i=1}^{N_{hid}} w_{ji} z_i\right)$$

Neuronale Netze - Training

How much did the weights contribute to the loss?



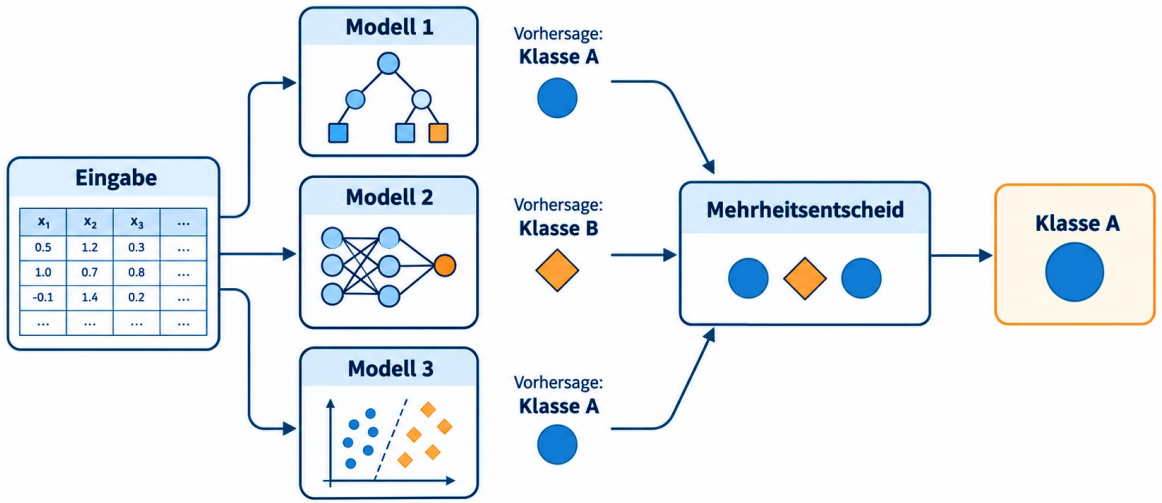
K-Means Clustering



Ensembling

Kombiniert mehrere Modelle und trifft finale Entscheidung über ein Votum.

Robustes Modell



Automated Machine Learning

Modellauswahl und Tuninig automatisieren

3

Sichtweise auf Optimierungsverfahren

- **Paradigmenwechsel:** Wandel von isolierter Algorithmen-Optimierung (Hyperparameter-Tuning, Architektur-Suche) hin zu geschlossenen, autonomen Entdeckungskreisläufen (*Closed-Loop Systemen*).

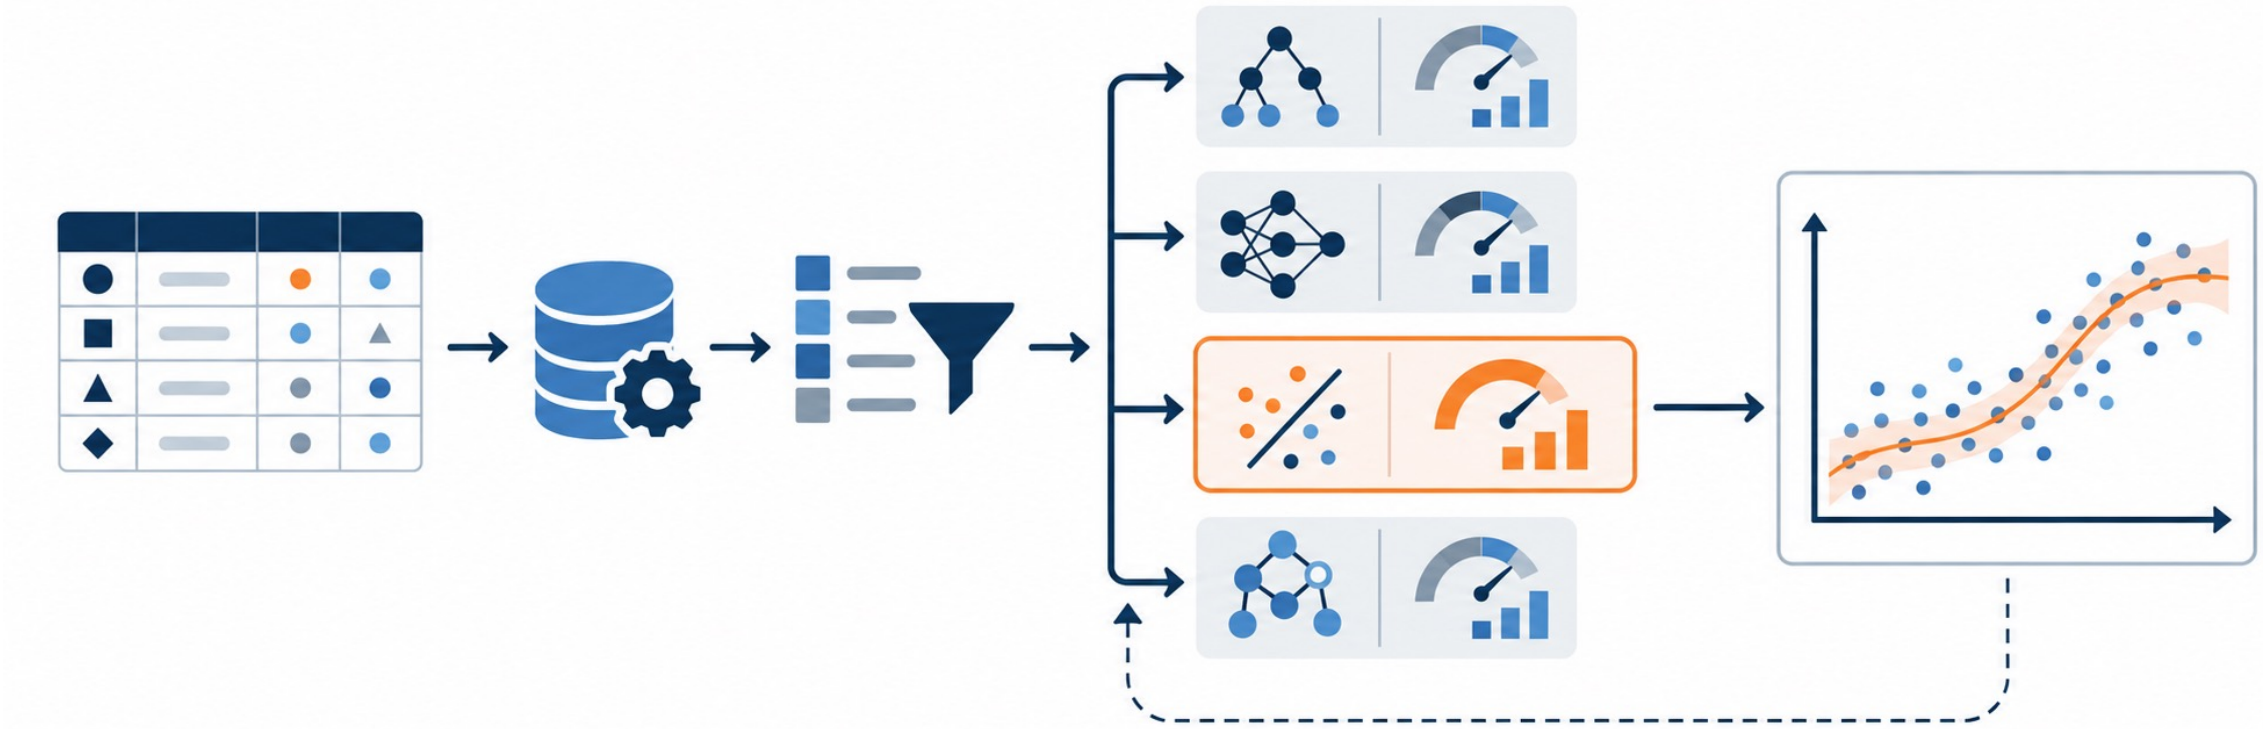
- **Systematisierung von ML-Pipelines:** Automatisierung zeitinvertiver und fehleranfälliger Schritte im Modellierungsprozess, um manuelle *Trial-and-Error*-Phasen zu reduzieren.

- **Ergänzung statt Ersatz:** Befähigung von Fachexperten zur schnellen Prototypisierung und Entlastung von Data Scientists bei Routineaufgaben.

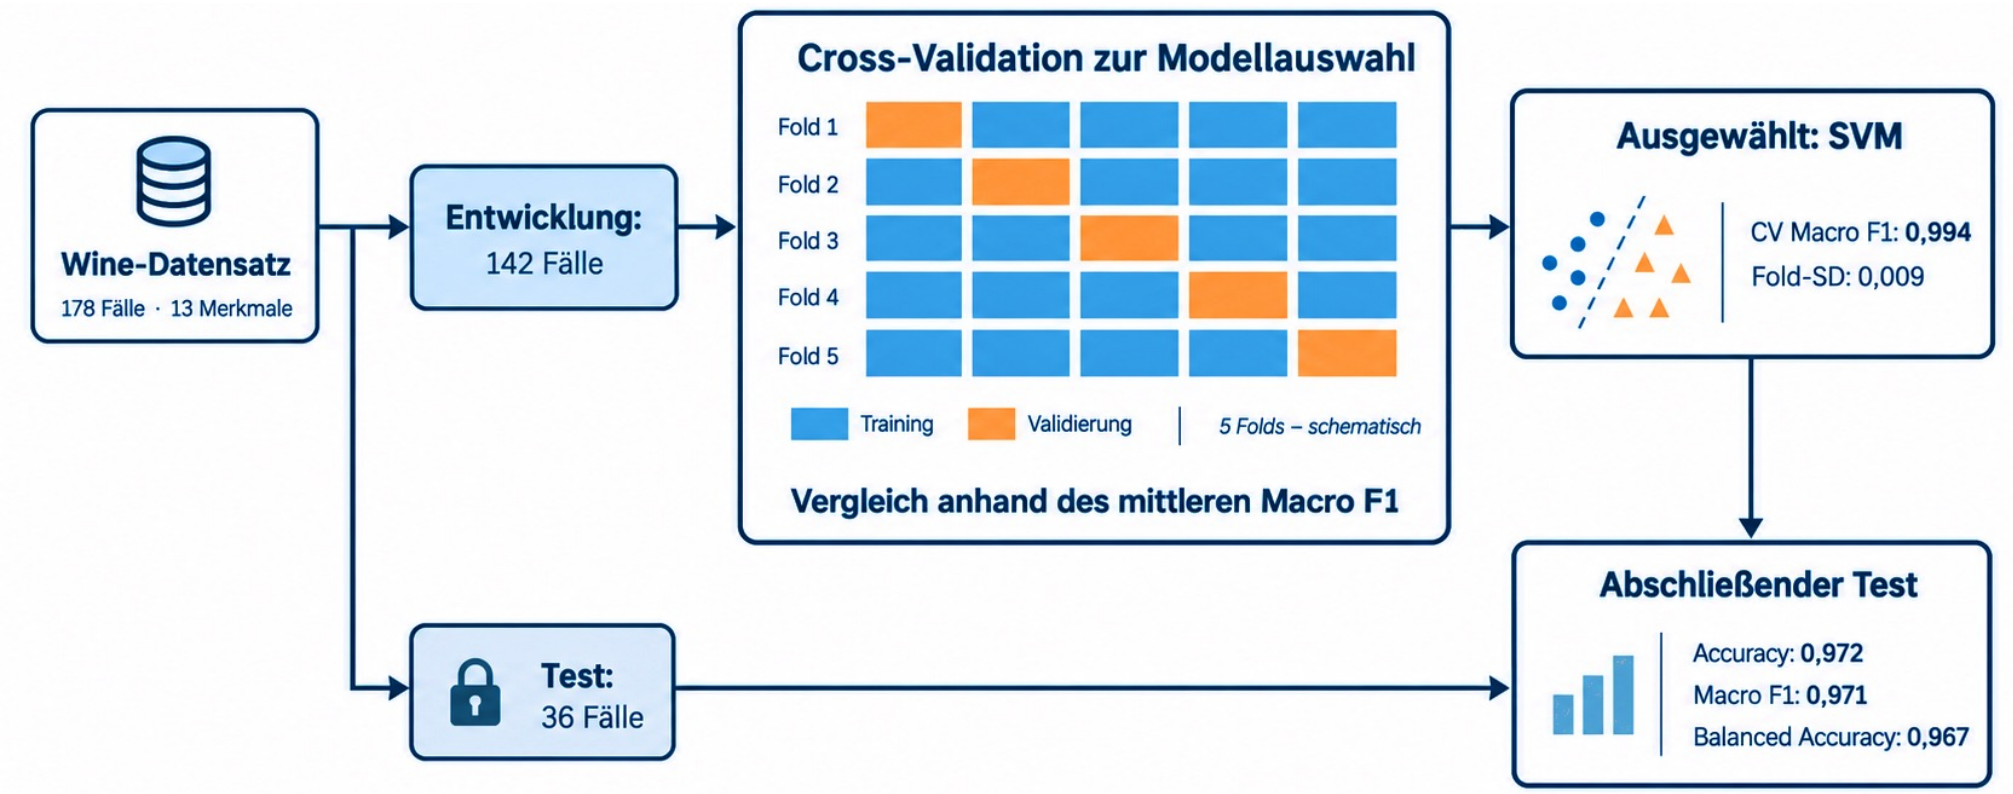
- **Drei Autonomie-Stufen:** Entwicklung von einfachen Automatisierungstools (*Tool*) über analytische Modellierungsassistenten (*Analyst*) bis hin zu eigenständigen KI-Wissenschaftlern (*Scientist*).

AutoML Pipelines

Datensatz Aufbereitung Modellvergleich Modellauswahl



Modellauswahl



AutoML – Automated Machine Learning

- **Cheminformatik & Wirkstoffforschung:**
  - **Auto-ADMET & ArtemisAI:** Automatische Erstellung maßgeschneiderter QSAR-/ADMET-Modelle zur Vorhersage molekularer Eigenschaften unter Vermeidung von *Domain Shifts*.
  - **Foundation Model Adaptation:** Automatische Anpassung großer Bio-Sequenzmodelle (z. B. GSK-Plattform) auf spezifische Assays via AutoML-Feature-Inferenz.

- **Materialwissenschaften & Katalyse:**
  - **Automatminer & Matbench:** Automatisierte Verarbeitungs-Pipelines für Zusammensetzungen und Kristallstrukturen, die ohne manuelles Tuning mit Crystal Graph Neural Networks (CGNNs) konkurrieren.

- **Physik & Astronomie:**
  - **Auto-PINNs:** Automatisierte Architektur- und Loss-Funktions-Suche für Physics-Informed Neural Networks zur Lösung partieller Differentialgleichungen.
  - **Astropartikelphysik:** Einsatz von AutoML auf Graph-Neural-Network-Suchräumen zur Energierekonstruktion nicht-euklidischer Detektordaten.

AutoML – Best Practices für die Wissenschaft

- **Strikte Trennung im Suchprozess:** Sämtliche Vorverarbeitungs-, Feature-Engineering- und Modellwahlschritte müssen strikt innerhalb von Kreuzvalidierungsschleifen (*Nested Cross-Validation*) evaluiert werden.

- **Transparenz & Reproduzierbarkeit:** Deklarative Konfigurationsdateien, automatisierte Nachverfolgung und Export des generierten Quellcodes anstelle von undokumentierten Klicksystemen.

- **Einhaltung von Berichtsstandards:** Überprüfung der automatisch erstellten Modelle

- **Domain Knowledge Integration (Human-in-the-Loop):** Einbetten von physikalischen Constraints und Expertenwissen zur sinnvollen Einschränkung des Suchraums und Sicherung der wissenschaftlichen Intentionalität.

AutoML Übung

https://huggingface.co/spaces/heinkehihn/AutoML

1. Welche Kennzahlen verwendet die App, um Modelle für Klassifikation beziehungsweise Regression auszuwählen?
2. Warum lernt die App die Werte für das Auffüllen fehlender Daten und die Standardisierung innerhalb jedes Trainingsfolds statt auf dem gesamten Datensatz?
3. Ein Modell erzielt einen hohen Trainingsscore, aber deutlich schlechtere Cross-Validation- und Testwerte: Welche Hinweise auf mögliche Ursachen findet ihr in den Ergebnissen der App?
4. Wie überzeugend ist das ausgewählte Modell, wenn ihr seine Vorhersageleistung, die Streuung zwischen den Folds, die Suchdauer und den Vergleich mit der Dummy-Baseline berücksichtigt?
5. Wie würdet ihr einen Versuchsplan entwerfen, um den Einfluss des Suchbudgets auf die Modellleistung zu untersuchen und dabei sicherzustellen, dass das Testset nicht zur Modellauswahl verwendet wird?

Lernen ohne Beispiele

Foundation Models, Zero Shot Learning und Transfer Learning

4

Lernen ohne Beispiele – Foundation Models

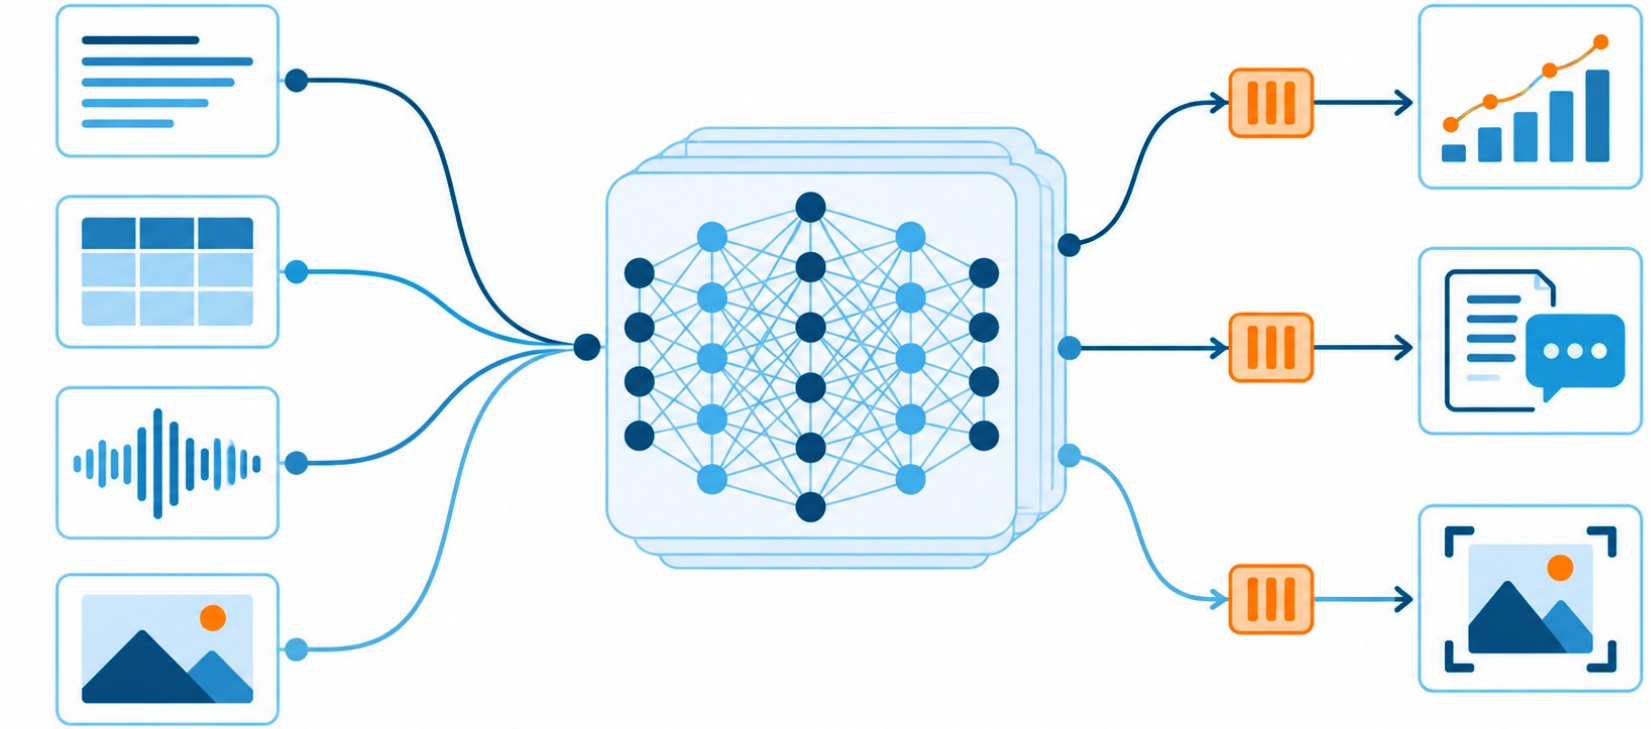
- **Vom Spezialmodell zum Foundation Model:** Wandel von eng definierten Einzelmodellen (z. B. für eine spezifische Proteinfamilie) hin zu universellen Basismodellen, die auf riesigen wissenschaftlichen Korpora vortrainiert werden.

- **Multimodale Repräsentationen:** Skaliertes Pre-Training auf unstrukturierten biologischen Sequenzen (DNA, RNA, Proteine), 3D-Molekülstrukturen, kontinuierlichen PDE-Feldern sowie Fachliteratur.

- **In-Context & Transfer Learning:** Fähigkeit zur Adaption an neue, ungesehene wissenschaftliche Fragestellungen via Zero-Shot oder Few-Shot In-Context Learning ohne vollständiges Re-Training.

- **Demokratisierung der Nutzung:** Bereitstellung standardisierter Schnittstellen ermöglicht es Fachexperten, vortrainierte Modelle ohne tiefe ML-Infrastrukturkenntnisse zu nutzen

Foundation Models



Foundation Models - Beispiele

- **Bio-Sequenzen & Makromoleküle:** Genom- und Protein-Foundation-Modelle (z. B. Borzoi, scGPT, RNA-FM, ESMFold) zur Vorhersage von Genregulation, Zelleinzelzuständen und de novo Proteindesign.

- **3D-Geometrie & Atomare Systeme:** Equivariante Graph Neural Networks (z. B. MACE, NequIP) unter Berücksichtigung von $E(3)/O(3)$-Symmetrien für universelle interatomare Potenziale und Moleküleigenschaften.

- **Tabular Foundation Models (TFMs):** Prior-Fitted Networks (z. B. TabPFN-3.5) für synthetisch vortrainiertes Zero-Shot-Lernen auf kleineren tabellarischen Datensätzen (z. B. Wirkstoff-Screening, ADMET).

- **Neural Operators & Kontinuierliche Felder:** Fourier Neural Operators (FNO) und DeepONet als Foundation Models für partielle Differentialgleichungen (z. B. Strömungsmechanik, Klimamodelle).

- **Vision Foundation Models:** Spezialisierte Modelle (z. B. Virchow, UNI) für hochauflösende digitale Pathologie und Mikroskopie.

Foundation Models - Risiken und Herausforderungen

- **Halluzinationen & Data Contamination:** Gefahr plausibel klingender, aber wissenschaftlich falscher Behauptungen sowie unbeabsichtigtes Auswendiglernen von Testdaten aus den Trainingskorpora.

- **High-Dimensionality & Memory Bottlenecks:** Hoher Speicher- und Rechenbedarf beim In-Context Processing extrem großer Tabellen oder Gigapixel-Bilder.

- **Out-of-Distribution (OOD) Generalisierung:** Leistungsabfall bei extremen physikalischen Regimes oder neuartigen chemischen Grundgerüsten, die nicht im Pre-Training enthalten waren.

- **Mangel an mechanistischem Verständnis:** Hohe prädiktive Genauigkeit liefert nicht automatisch ein Kausalverständnis der physikalischen oder biologischen Prozesse (*Black-Box-Problem*).

Foundation Models - Übung

https://huggingface.co/spaces/heinkehihn/Segmentation

1. Warum können Vordergrund- und Hintergrundpunkte die Segmentierung verändern, obwohl die Modellgewichte unverändert bleiben?
2. Welche Veränderungen beobachtet ihr bei Anzahl, Detailgrad und Überlappung der Masken sowie bei der Laufzeit, wenn ihr die automatische Abtastung von 8 auf 32 Punkte pro Seite erhöht?
3. Wie würdet ihr beurteilen, ob eine Maske für eure wissenschaftliche Fragestellung geeignet ist, wenn der angezeigte Qualitätsscore lediglich eine Modellschätzung und keine gemessene Genauigkeit ist?

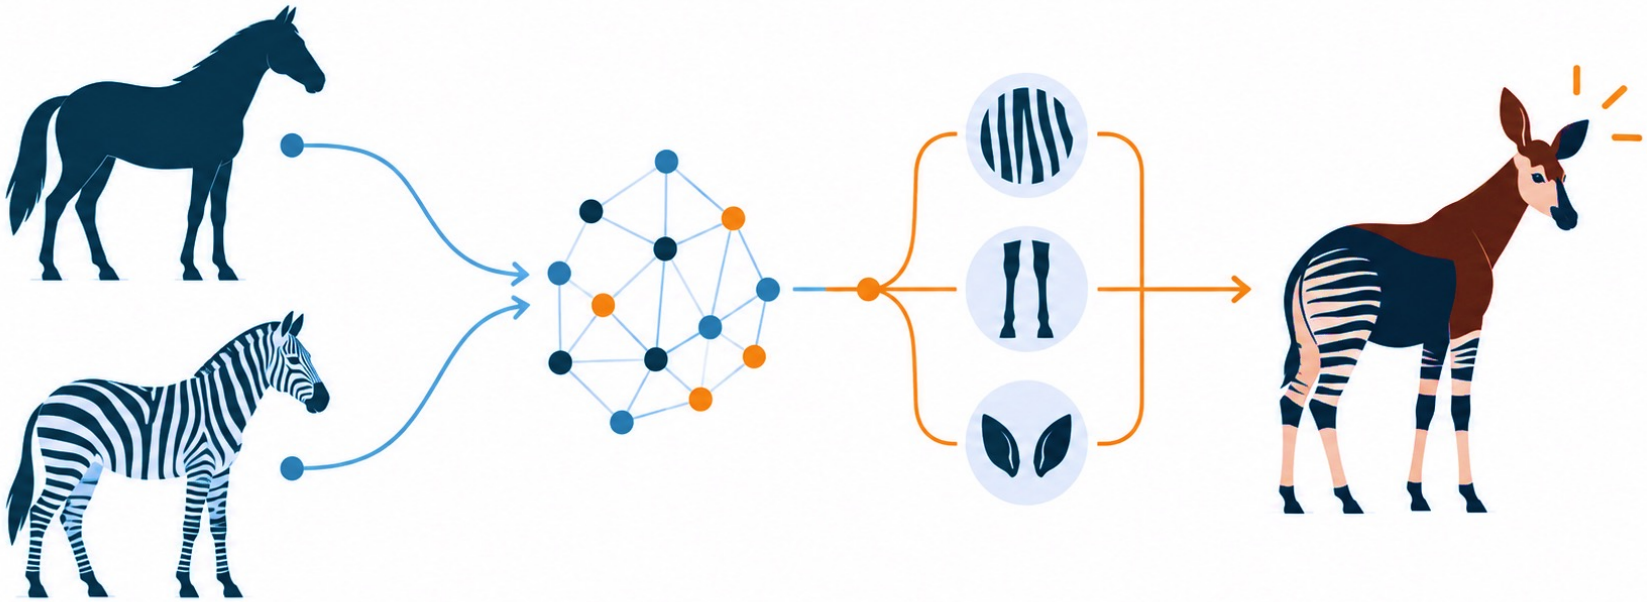
Zero Shot Learning

Use Case: Ich will unstrukturierte Objekte Klassifizieren, kann oder will aber kein Modell trainierien.

Vorgehen: Ich suche für meinen Datentyp ein vortrainiertes Modell und nutze dieses.

Beispiel: Begriffe sollen vereinheilicht werden, z.B. unterschiedliche Bezeichnungen für die selbe Berufsbezeichnung. Einem Zero Shot modell gebe ich den Begriff und eine Liste an Möglichkeiten, das Modell wählt dann die beste Passung aus.

Zero Shot Learning



Zero Shot Learning - Übung

https://huggingface.co/spaces/heinkehihn/ZeroShotClassification

1. Warum kann die App Texte anhand selbst gewählter Labels klassifizieren, ohne dafür mit eigenen Trainingsbeispielen trainiert zu werden?
2. Wie verändern sich die Scores und die ausgewählten Labels, wenn ihr bei gleichbleibendem Text ein ähnlich formuliertes Label ergänzt und zwischen Single-Label- und Multi-Label-Modus wechselt?
3. Wie würdet ihr die Aussage beurteilen, dass ein Label mit einem Score von 0,9 mit 90-prozentiger Wahrscheinlichkeit korrekt ist, und welche Überprüfung wäre dafür erforderlich?

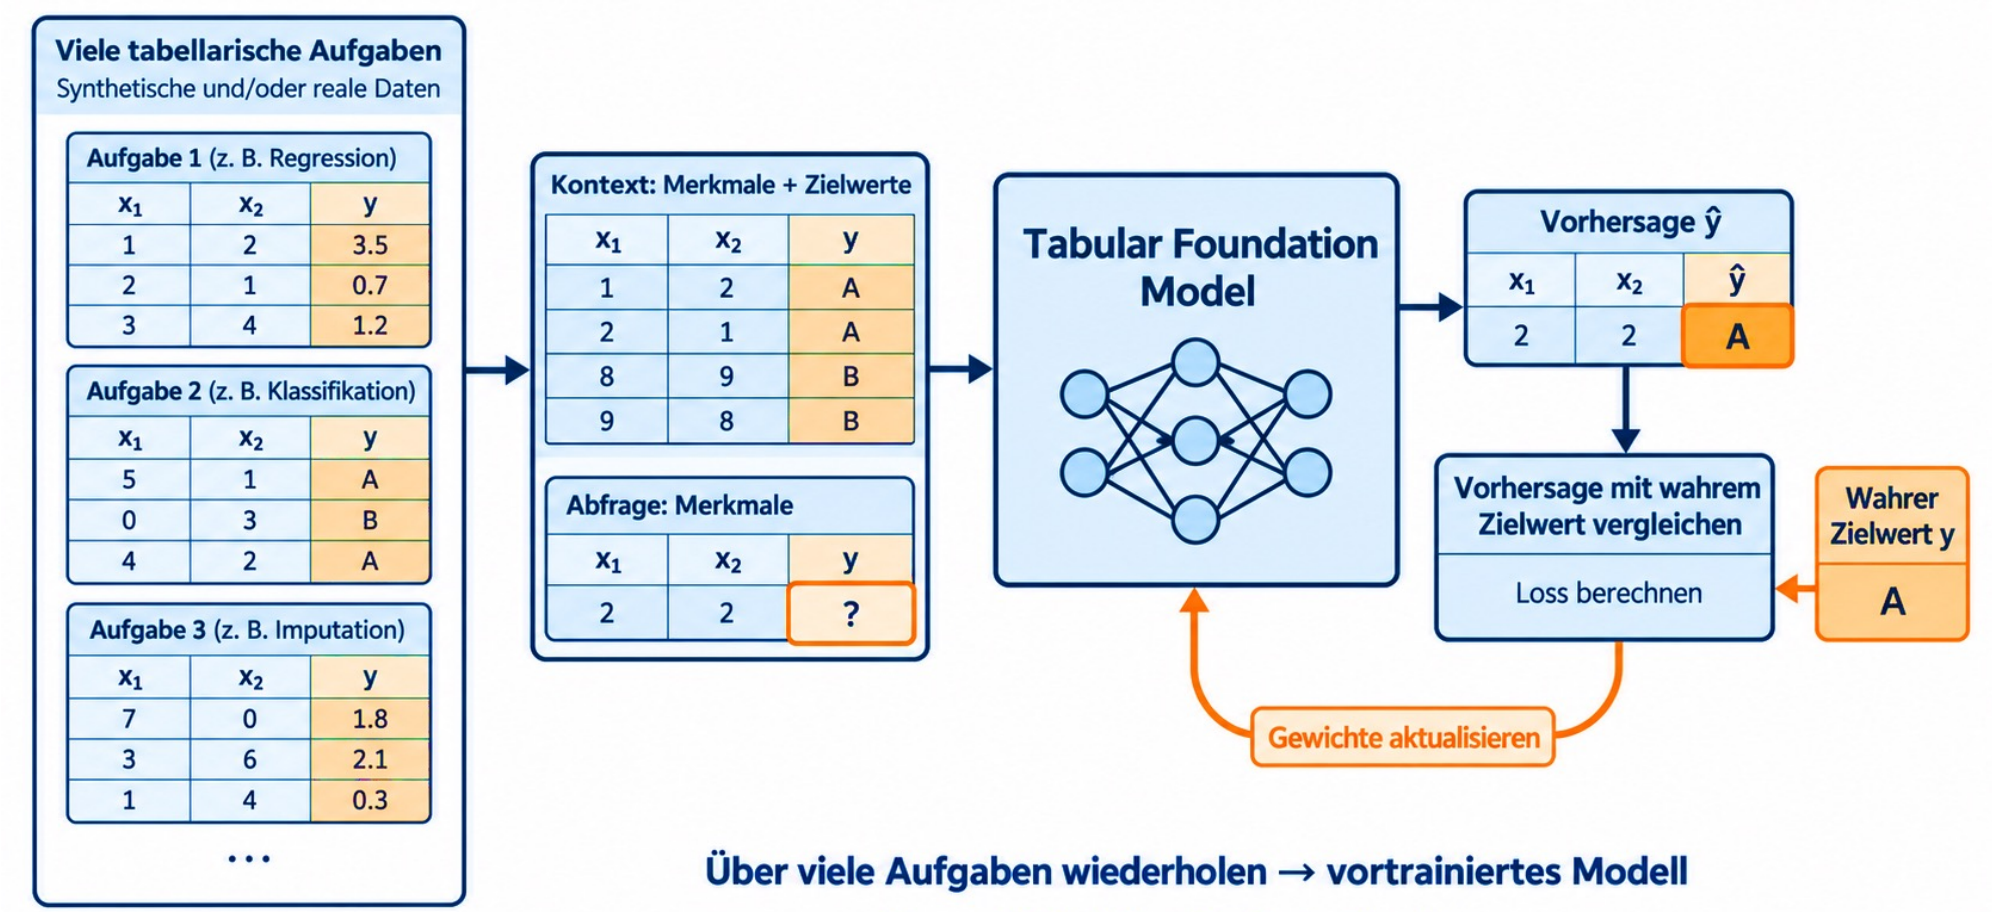
In-Context Learning für Tabulare Daten

Use Case: Ich habe tabulare Daten, will/kann kein Modell trainieren, brauche aber Vorhersagen für neue Daten

Vorgehen: Ich suche mir ein Tabuarl Foundation Model, zeige diesem meine Daten als ”Kontext” und lasse mir Vorhersagen für neue Daten geben.

Beispiel: Basierend auf Genomen will ich eine seltene Krankeit erkennen, habe nur wenige Beispieldaten. Dann suche ich ein tabulares Foundation Model, nutze meine Daten als Kontext und klassifiziere neue Patientendaten mit dem Modell.

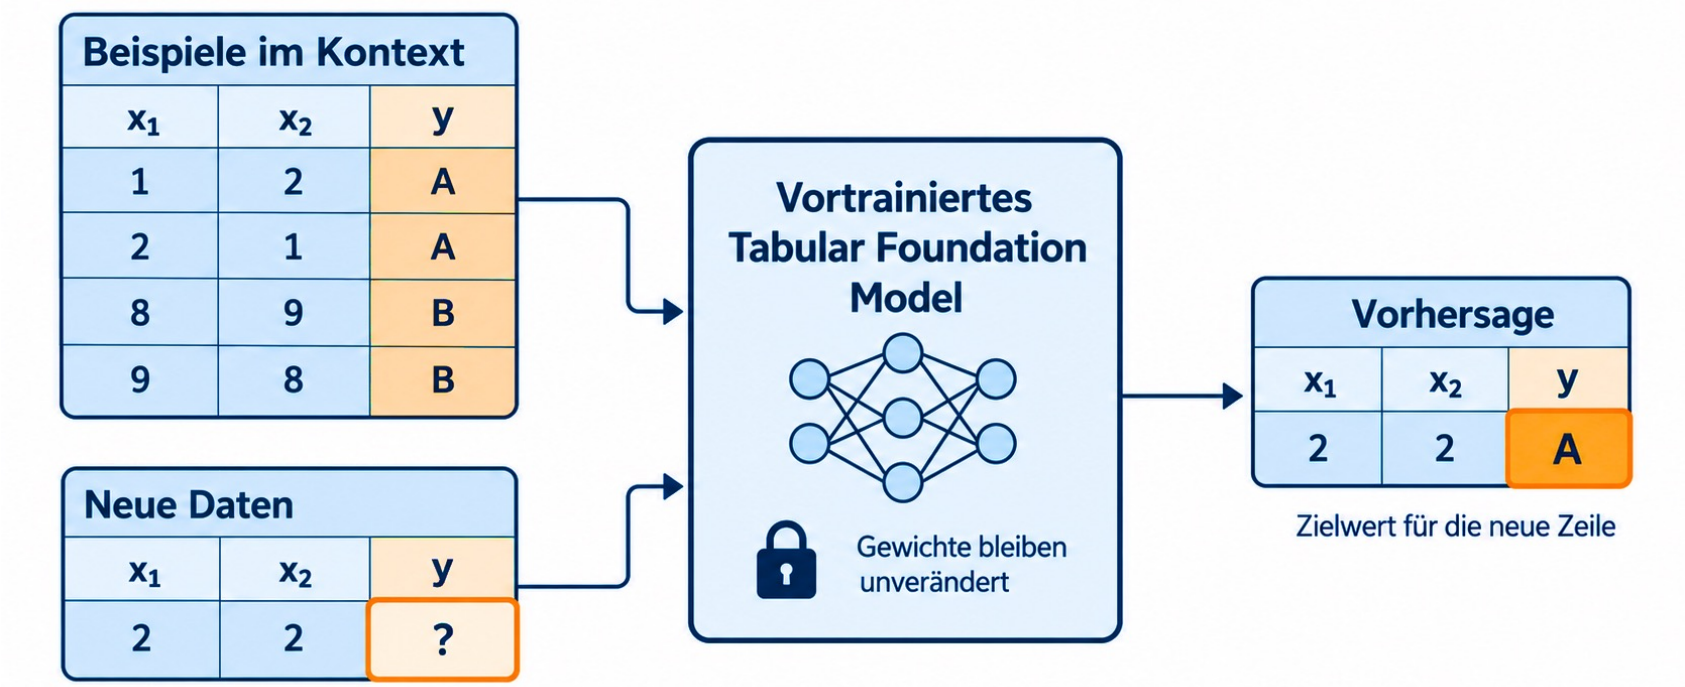
In-Context Learning für Tabulare Daten



In-Context Learning

Merkmal	Klassisches ML (GBDTs / MLPs)	Tabular In-Context Learning (TFMs)
Trainingsphase	Explizites Training / Fit auf dem spezifischen Datensatz	Keines. Gewichte bleiben komplett gefroren (Frozen Weights)
Hyperparameter (HPO)	Zeit- und rechenintensives Tuning pro Datensatz	Entfällt vollständig (Out-of-the-Box nutzbar)
API vs. Mechanik	.fit() trainiert das Modell; .predict() evaluiert	.fit() speichert den Kontext; .predict() führt die gemeinsame ICL-Inferenz aus
Gedächtnis	Speichert gelernte Regeln in Baumstrukturen/Gewichten	Behält den Trainingskontext beim Inferenzschritt im Speicher

Vorhersage durch In-Context Learning



Tabular Foundation Models - Übung

https://huggingface.co/spaces/heinkehihn/TabularData

1. Welche Aufgaben haben die gelabelten Kontextdaten und die ungelabelten Anfragedaten bei der Vorhersage mit Kumo?
2. Wie verändern sich Macro F1, die Ergebnisse einzelner Klassen und die Inferenzzeit, wenn ihr bei gleicher Modellgröße und gleichem Zufallsseed den Anteil der Kontextdaten erhöht?
3. Wie überzeugend ist die Aussage „Das größere Modell ist besser“, wenn ihr den Vergleich mit der Mehrheitsbaseline, unterschiedliche Zufallsseeds und die Inferenzzeit berücksichtigt?

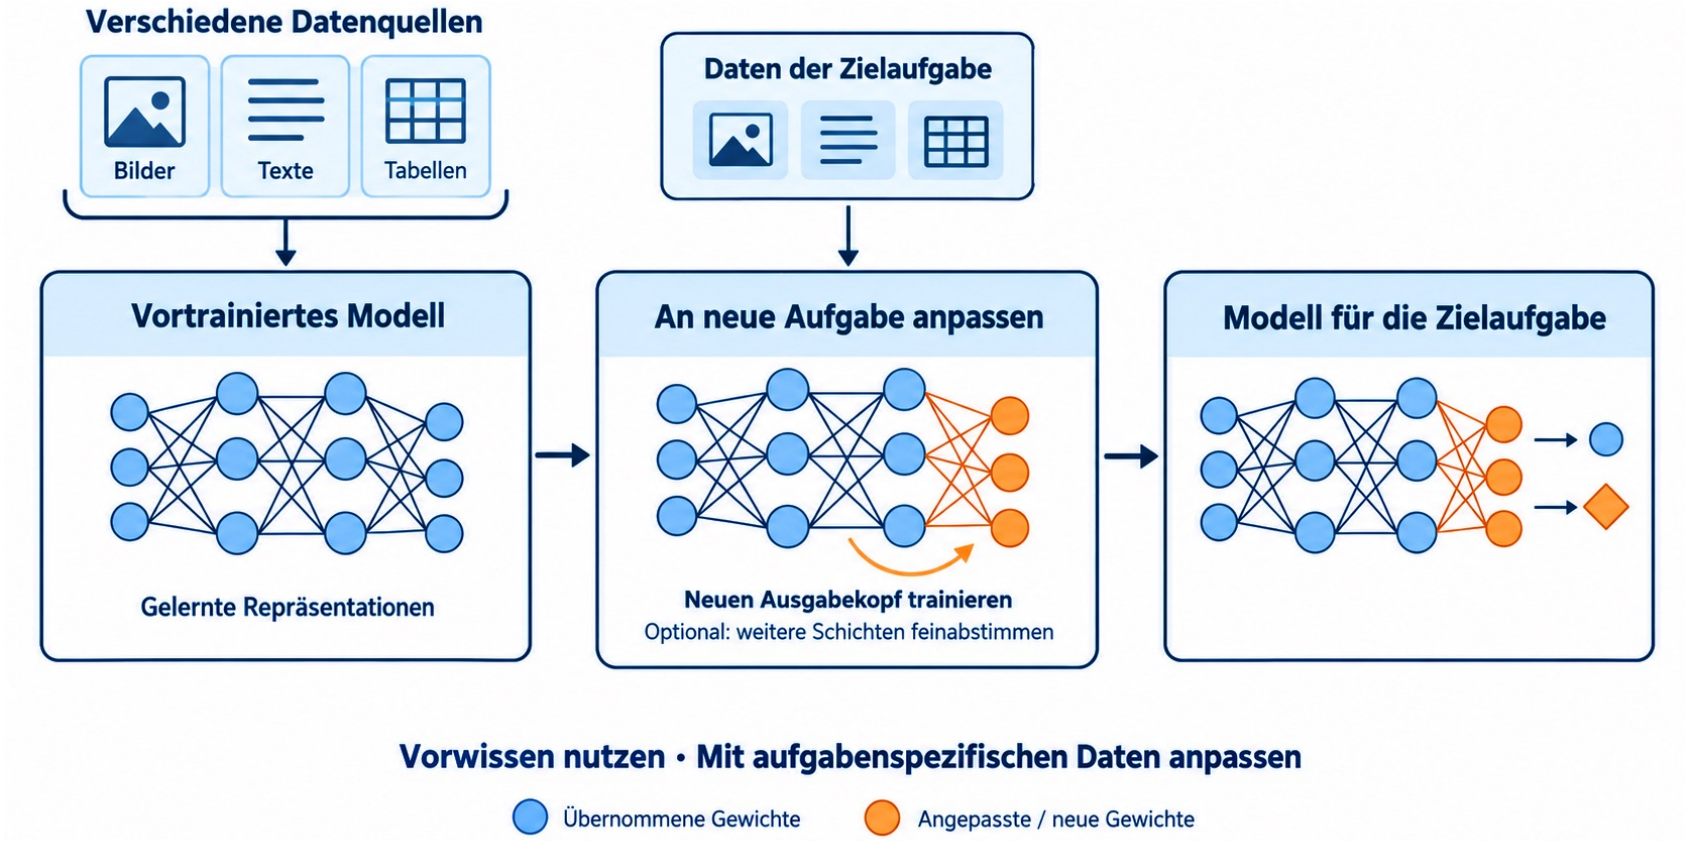
Transfer Learning

Use Case: es existiert nur ein kleiner Datensatz, der aber als ein Spezialfall von einem allgemeineren Problem verstanden werden kann

Vorgehen: Ein vortrainiertes Modell wird genommen, Teile davon werden “eingefroren” und es wird auf dem kleinen, spezialisierten Datensatz trainiert

Beispiel: Bilderkennung soll feststellen, ob eine Pflanze mit einer Krankheit befallen ist. Es gibr nur wenige annotierte Beispiele. Aber: Es gibt viele Modelle, die millionen Bildern vortrainiert wird. Eventuell lässt sich dieses Wissen übertragen (=Transfer)?

Transfer Learning



Transfer Learning - Übung

https://huggingface.co/spaces/heinkehihn/TransferLearning

1. Warum können Bildmerkmale, die MobileNetV2 auf ImageNet gelernt hat, auch beim Erkennen von Krankheiten auf Bohnenblättern helfen?
2. Woran erkennst du in den Lernkurven, dass zusätzliche Trainingsepochen zu Overfitting führen?
3. Welche Ergebnisse aus der App würden dich davon überzeugen, dass vortrainierte Merkmale bei wenigen Trainingsbildern hilfreicher sind als verkleinerte Bildpixel?
4. Wie würdest du mit der App eine Versuchsreihe entwerfen, um herauszufinden, wie viele beschriftete Blattbilder du für eine selbst festgelegte Validierungsgenauigkeit benötigst?

Entwicklung von ML Workflows

Systematische Modelle

5

Reproduzierbare Forschung im ML Kontext



REFORMS – Recommendations for Machine Learning Based Science

- **Studienziele (Study goals):** Eindeutige Definition der Zielpopulation und Begründung für den Einsatz von ML.
- **Rechnerische Reproduzierbarkeit (Computational reproducibility):** Bereitstellung von Code, Datensatz-DOIs, Skripten und Angaben zur Infrastruktur.
- **Datenqualität (Data quality):** Transparente Dokumentation von Datenquellen, Stichprobenziehung, Annotationsprozessen und Repräsentativität.
- **Datenvorverarbeitung (Data preprocessing):** Vollständige Offenlegung aller Transformations- und Imputationsschritte (bevorzugt per Flussdiagramm).
- **Modellierung (Modeling):** Detaillierte Beschreibung der Modellarchitekturen, des Hyperparametertunings und der gewählten Baselines.
- **Data Leakage (Data leakage):** Strikter Nachweis der sauberen Trennung von Trainings- und Testdaten sowie der zeitlichen/räumlichen Legitimität aller Features.
- **Metriken und Unsicherheit (Metrics and uncertainty):** Wahl aufgabengerechter Performanzmaße und Angabe von Unsicherheitsintervallen.
- **Generalisierbarkeit und Grenzen (Generalizability and limitations):** Nachweis externer Validität und explizite Nennung von Szenarien, in denen das Modell nicht funktioniert.

Kapoor, S., Cantrell, E. M., Peng, K., Pham, T. H., Bail, C. A., Gundersen, O. E., ... & Narayanan, A. (2024). REFORMS: Consensus-based Recommendations for Machine-learning-based Science. *Science Advances*, *10*(18), eadk3452.

REFORMS – ML Based Science entwickeln

Phase	Leitfrage	Konkretes Ergebnis
1. Forschungsfrage und Erkenntnisziel	Welche wissenschaftliche Aussage wollen wir untersuchen, und welchen Beitrag soll ML leisten?	Forschungsfrage, Zielpopulation und Rolle des Modells
2. Untersuchungs- und Evaluationsplan	Welche Daten und welche Prüfung benötigen wir, um diese Aussage zu begründen?	Datenbedarf, Vorhersagezeitpunkt, Splitstrategie, Baselines und Metriken
3. Daten verstehen und aufbereiten	Wie wurden die Daten erzeugt, was messen sie, und welche Abhängigkeiten bestehen?	Dokumentierter Datensatz und reproduzierbare Vorverarbeitung
4. Modelle entwickeln und auswählen	Welche Verfahren sind geeignet, und wie wählen wir zwischen ihnen?	Baseline, Modellvergleich und dokumentierter Suchprozess
5. Ergebnisse prüfen	Wie gut, wie stabil und für welche Population funktioniert das Modell?	Unabhängige Evaluation, Unsicherheits- und Robustheitsanalysen
6. Wissenschaftlich interpretieren und teilen	Welche Schlussfolgerung tragen die Ergebnisse tatsächlich?	Begründete Aussage, Grenzen, Code und Reproduktionsanleitung

Kapoor, S., Cantrell, E. M., Peng, K., Pham, T. H., Bail, C. A., Gundersen, O. E., ... & Narayanan, A. (2024). REFORMS: Consensus-based Recommendations for Machine-learning-based Science. *Science Advances*, *10*(18), eadk3452.

Machine Learning Based Science Planen

Für die Hands-On Projektarbeit entweder

- Einen eigenen Use-Case ausdenken
- Einen bereits bestehenden aus der eigenen Forschung nehmen

Und diesen mit dem REFORMS Framework ausarbeiten.

Dazu entweder:

- über ChatGPT das Plugin installieren:
- ohne ChatGPT mithilfe der Originalarbeit https://www.science.org/doi/pdf/10.1126/sciadv.adk3452